# Predicting Kissat Performance with Satzilla

**vorgelegt an der**
**Albert-Ludwigs-Universität Freiburg**

**von Rosas, Paulo**
**4141122**

2. Mai 2026

universität freiburg

# Bachelor's Thesis

Submitted on **May 2, 2026**
to the **Albert-Ludwigs-Universität Freiburg**
by **Paulo Rosas** (4141122)
Examined by **Prof. Dr. Mathias Fleury**

**Computer Architecture**
Department of Computer Science
Faculty of Engineering
Albert-Ludwigs-Universität Freiburg

# Erklärung

Hiermit erkläre ich, dass ich diese Abschlussarbeit selbständig verfasst habe, keine anderen als die angegebenen Quellen/Hilfsmittel verwendet habe und alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten Schriften entnommen wurden, als solche kenntlich gemacht habe.

Darüber hinaus erkläre ich, dass diese Abschlussarbeit nicht, auch nicht auszugsweise, bereits für eine andere Prüfung angefertigt wurde

Freiburg, May 2, 2026

| | |
|---|---|
| Ort, Datum | Paulo Rosas |

# Danksagung

Mein besonderer Dank gilt meinem Tutor Dr. Mathias Fleury für die ausgezeichnete Betreuung, die wertvollen Hinweise und die kontinuierliche Unterstützung während der Erstellung dieser Arbeit.

# Contents


**1 Einleitung** **1**
1.1 Warum SAT wichtig ist . . . 2
1.2 Motivation . . . 4

**2 Preliminaries** **5**
2.1 Conjunctive Normal Form (CNF) . . . 5
2.2 Kissat . . . 6
2.2.1 Kissat Architektur . . . 6
2.2.2 Kissat-Konfigurationsvarianten . . . 9
2.2.3 Messung der Solver-Leistung . . . 9
2.3 SATzilla . . . 10
2.3.1 Funktionsweise . . . 10
2.3.2 Feature Extraction . . . 11
2.3.3 Machine Learning Model . . . 11
2.3.4 Training und Prediction Pipeline . . . 12

**3 Satzilla Outcome** **13**
3.1 Validierung mit Fake Solvern . . . 13
3.1.1 Design der fake Solver . . . 13
3.1.2 Resultate . . . 14
3.1.3 Interpretation . . . 14
3.2 Trainieren auf echten Kissat Solver Daten . . . 16
3.2.1 Dataset . . . 16
3.2.2 Training Konfiguration . . . 16
3.2.3 Testgenauigkeit . . . 16
3.3 Top-K-Genauigkeit: Der Wert des „fast Richtigen“ . . . 18
3.3.1 Resultate . . . 18
3.3.2 Interpretation – Zeitlicher Vorteil gegenüber dem Standard-Solver 19
3.4 Feature Importance Analysis . . . 21
3.4.1 Wichtigste Features . . . 21
3.4.2 Was die Features tatsächlich messen . . . 22
3.4.3 Feature Kategorien – Zusammenfassung . . . 25
3.5 Per-Solver Performance . . . 27
3.5.1 Interpretation . . . 28
3.6 Auswirkungen der Einbindung von LP-Features . . . 29
3.6.1 Ergebnis . . . 29
3.6.2 Interpretation . . . 29
3.7 Zusammenfassung der wichtigsten Ergebnisse . . . 30
3.8 Fazit . . . 31

**4 Kissat Results** **32**
4.1 Setup . . . . . 34
4.1.1 Feature Extraction Process . . . . . 34
4.1.2 SATZilla Model Training . . . . . 35
4.2 Auswirkungen der Vorverarbeitung auf die Vorhersagen von SATZilla . . 37
4.2.1 Veränderungen der Vorhersageverteilung . . . . . 37
4.2.2 Änderungen der Vorhersagen nach Vorverarbeitungsstufe . . . . 38
4.2.3 Analyse der Solver-Migration . . . . . 40
4.3 Abschließende Schlussfolgerung: Was uns diese Ergebnisse sagen . . 42
4.3.1 Fazit . . . . . 44
4.4 Vergleich der Featuresbedeutung für Pre10k und Pre100k . . . . . 45
4.4.1 Wichtigste Features für jede Vorverarbeitungsstufe . . . . . 45
4.4.2 Fazit . . . . . 47
4.5 Laufzeitvergleich Pre10k vs. Pre100k . . . . . 48
4.5.1 Ergebnisse Pre10k (10.000 Simplifikationsschritte) . . . . . 49
4.5.2 Ergebnisse Pre100k (100.000 Simplifikationsschritte) . . . . . 51
4.5.3 Wichtige Erkenntnisse . . . . . 52
4.5.4 Interpretation . . . . . 53
4.5.5 Fazit . . . . . 53

**5 Conclusion** **54**
5.1 Technische Daten . . . . . 55

**List of Figures** **II**

**List of Tables** **III**

**References** **V**

# 1 Einleitung

Das Erfüllbarkeitsproblem der Aussagenlogik (SAT, von englisch satisfabiality "Erfüllbarkeit") ist ein fundamentales Problem der Informatik mit kritischen Anwendungen in Software und Hardware Überprüfung, im automatisierten Testen, in der Planung, in der Bioinformatik sowie in vielen weiteren Bereichen der Computer-Aided Design und der Künstlichen Intelligenz.

Aufgrund seiner zentralen Bedeutung für die Komplexitätstheorie – SAT war das erste nachgewiesene NP-vollständige Problem –[10] dient es als Ausgangspunkt für die Analyse unzähliger weiterer algorithmischer Fragestellungen. Die typische Eingabe für SAT-Solver ist eine aussagenlogische Formel in konjunktiver Normalform (KNF), also eine Konjunktion von Klauseln, wobei jede Klausel eine Disjunktion von Literalen (Variablen oder negierten Variablen) darstellt.

Die Frage, ob eine solche Formel erfüllbar ist – das heißt, ob es eine Belegung der booleschen Variablen mit den Werten wahr oder falsch gibt, die die gesamte Formel wahr macht – ist entscheidungsrelevant: Erfüllbare Formeln belegen die Korrektheit eines Modells, während unerfüllbare Formeln beweisen, dass keine solche Belegung existiert.

Fortschritte in der SAT-Lösungstechnologie, insbesondere durch das CDCL (Conflict-Driven Clause Learning)-Verfahren, haben es ermöglicht, Instanzen mit Millionen von Variablen und Klauseln effizient zu lösen[7]. Dadurch ist SAT zu einem praktischen Werkzeug für viele reale Anwendungen geworden, bei denen komplexe logische Bedingungen geprüft werden müssen.[11]

## 1.1 Warum SAT wichtig ist

Trotz seiner theoretischen Bedeutung als erstes NP-vollständiges Problem hat SAT breite praktische Anwendung in den Bereichen Hardware-Verifikation, Software-Testing, Planung und künstliche Intelligenz gefunden.[6]

Moderne SAT-solver haben in den letzten zwei Jahrzenten bemerkenswerte fortschritte gemacht; Löser wie Kissat sind in der Lage, industrielle Instanzen mit Millionen von Variablen zu lösen.[3]

SAT hat breite praktische Anwendung gefunden, da sich viele Probleme aus der realen Welt als SAT-Instanzen formulieren lassen:[11]

- **Hardware-Verifikation**: Nachweis, dass sich digitale Schaltungen korrekt verhalten
- **Softwaretests**: Erstellung von Testfällen, die bestimmte Pfade abdecken
- **Planung**: Ermittlung von Handlungsabläufen, mit denen Ziele erreicht werden
- **Kryptoanalyse**: Knacken kryptografischer Systeme durch das Lösen logischer Beschränkungen
- **Bioinformatik**: Analyse genetischer Sequenzen und Proteinfaltung

Die praktische Bedeutung von SAT hat jahrzehntelange Forschungen zur Entwicklung effizienter SAT-Löser vorangetrieben. Die zugrundeliegenden Benchmark-Instanzen für diese Arbeit wurden der SAT Competition 2024 entnommen.[12]

Der praktische Erfolg der SAT-Lösung ist weitgehend auf die bemerkenswerte Leistungsfähigkeit von CDCL-Lösern (Conflict-Driven Clause Learning) zurückzuführen[7]. In der SAT-Forschung ist jedoch bekannt, dass kein einzelner Löser bei allen Instanzen allen anderen überlegen ist[16]. Verschiedene Solver weisen komplementäre Leistungsmerkmale auf – ein Solver, der bei einer Instanzfamilie extrem schnell ist, kann bei einer anderen schlecht abschneiden. Diese Beobachtung hat zur Entwicklung von Algorithmusauswahlsystemen geführt, die automatisch den für eine bestimmte Instanz am besten geeigneten Solver auswählen.

Diese Erkenntnis hat zur Entwicklung des portfoliabasierten SAT-Lösens geführt, bei dem eine Sammlung von Solvern gepflegt wird und ein Auswahlmechanismus entscheidet, welcher Solver für eine bestimmte Instanz eingesetzt wird[17]. Die zugrunde liegende Idee ist einfach, aber wirkungsvoll: Wenn wir vorhersagen können, welcher Solver bei einer Instanz die beste Leistung erbringt, können wir erhebliche Rechenzeit

einsparen, indem wir Solver mit schlechter Leistung vermeiden.

SATZilla ist ein solches System, das auf der Extraktion struktureller Merkmale aus SAT-Instanzen basiert[15]. Die Implementierung des modernisierten Feature-Extraktors ist öffentlich zugänglich und wurde für diese Arbeit verwendet.

## 1.2 Motivation

Im ursprünglichen Bachelorprojekt, das dieser Arbeit zugrunde liegt, bestand die Aufgabe darin, Satzilla im Jahr 2025 mit neuen Daten zu replizieren, um einen Vergleich der Vorhersagen mit den Ergebnissen aus dem Jahr 2024 zu ermöglichen.

Die Durchführung der Arbeit war mit technischen Herausforderungen verbunden. Insbesondere waren bestimmte Dateien nicht verfügbar, was die Kontaktaufnahme mit dem Autor der Satzilla-Implementierung erforderte. Darüber hinaus erwies sich die lokale Recheninfrastruktur für die benötigten Vorhersagen als unzureichend, insbesondere hinsichtlich des verfügbaren Arbeitsspeichers.

Durch die Bereitstellung eines Hochleistungsrechners der Universität, der mittels SSH-Verbindung genutzt werden konnte, konnten die erforderlichen Berechnungen dennoch abgeschlossen werden. Die benötigten Laufzeiten der Kissat-Varianten sowie die vorverarbeiteten Benchmark-Datensätze wurden vom Betreuer über eine Nextcloud-Freigabe zur Verfügung gestellt.[1]

Der Haupteil dieser Arbeit beschäftigt sich mit der Vohersage von Solvern, nicht mit der Laufzeit. SATZilla empfiehlt zum jeweiligen Solver ebenfalls eine Vorhergesehene Laufzeit mit empirischen Härtemodellen (EPMs) ,diese können aber Stark von der tatsächlichen Laufzeit des Solvers abweichen.[14]

Im Rahmen dieser Arbeit lag der Fokus auf der Analyse der von Satzilla für die jeweiligen Benchmarks empfohlenen Solver sowie der zugehörigen Laufzeiten.

Die vorliegende Arbeit untersucht zwei zentrale Fragestellungen:

1. Ob Satzilla erfolgreich auf bestimmte Kissat-Konfigurationen trainiert werden kann, d.h. ob das Modell korrekte Vorhersagen trifft. Hierzu war zunächst eine Validierung der zugrundeliegenden Machine-Learning-Pipeline erforderlich, da die Ergebnisse des ursprünglichen Projekts Zweifel an deren Funktionsfähigkeit aufkommen ließen.

2. Ob bessere Ergebnisse erzielt werden, wenn Satzilla mit Kissat trainiert und anschließend auf vorverarbeitete Benchmark-Datensätze angewendet wird – konkret auf die Vereinfachungsstufen Pre10k und Pre100k. Diese Fragestellung wurde in dieser Form bislang nicht untersucht.

# 2 Preliminaries

In diesem Kapitel werden die Grundlagen die für die Späteren Kapitel von bedeutung sein werden erklärt. Zuerst was CNF Dateien sind un wie sie aufgebaut sind, dann was Kissat und Satzilla sind und wie sie mit Dateien trainiert werden um Predicitons von Solvern zu machen.

## 2.1 Conjunctive Normal Form (CNF)

Bei einer Boolschen Formel, die aus durch UND- und ODER-Operatoren verbunden Variablen besteht, (AND $\wedge$, OR $\vee$, NOT $\neg$) geht es beim SAT-Problem um die Frage, ob es eine Zuorndung von Warheitswerten zu den Variablen gibt, bei der die gesamte Formel als Wahr ausgewertet wird.

Moderne SAT-Löser arbeiten in der Regel mit Formeln in konjunktiver Normalform (CNF). Eine CNF-Formel besteht aus:

- **Variablen**: Boolesche Variablen (z. B. $x_1$, $x_2$, ..., $x_n$)
- **Literale**: Eine Variable oder deren Negation (z. B. $x_1$ oder $\neg x_1$)
- **Klauseln**: Eine Disjunktion (ODER) von Literalen (z. B. $(x_1 \vee \neg x_2 \vee x_3)$)
- **Formel**: Eine Konjunktion (UND) von Satzteilen (z. B. $(x_1 \vee \neg x_2) \wedge (\neg x_1 \vee x_3) \wedge (x_2 \vee \neg x_3)$

Das CNF-Format ist sowohl ausdrucksstark (jede Boolesche Formel lässt sich in CNF umwandeln) als auch für algorithmisches Denken gut geeignet. Das folgende Beispiel zeigt eine einfache CNF-Datei:

```
p cnf 3 4
1 -2 0
-1 3 0
2 -3 0
-1 -2 -3 0
```

Dies stellt eine Formel mit 3 Variablen und 4 Klauseln dar. Die Spalte „p cnf“ gibt den Problemtyp und die Dimensionen an (3 Variablen, 4 Klauseln), und jede nachfolgende Spalte stellt eine Klausel dar, die mit 0 endet.

## 2.2 Kissat

Kissat ist ein hochmoderner SAT-Löser nach dem Prinzip des Conflict-Driven Clause Learning (CDCL), der von Armin Biere und seiner Forschungsgruppe an der Johannes Kepler Universität Linz entwickelt wurde. Der Kissat-SAT-Solver ist eine komprimierte und verbesserte Neuimplementierung von CaDiCaL in C. Er verfügt über verbesserte Datenstrukturen, eine optimierte Ablaufplanung der Datenverarbeitung sowie optimierte Algorithmen und Implementierungen.[2]

Kissat belegte den ersten Platz in der Hauptkategorie des SAT-Wettbewerbs 2020 und den ersten Platz bei den unlösbaren Instanzen.[8]

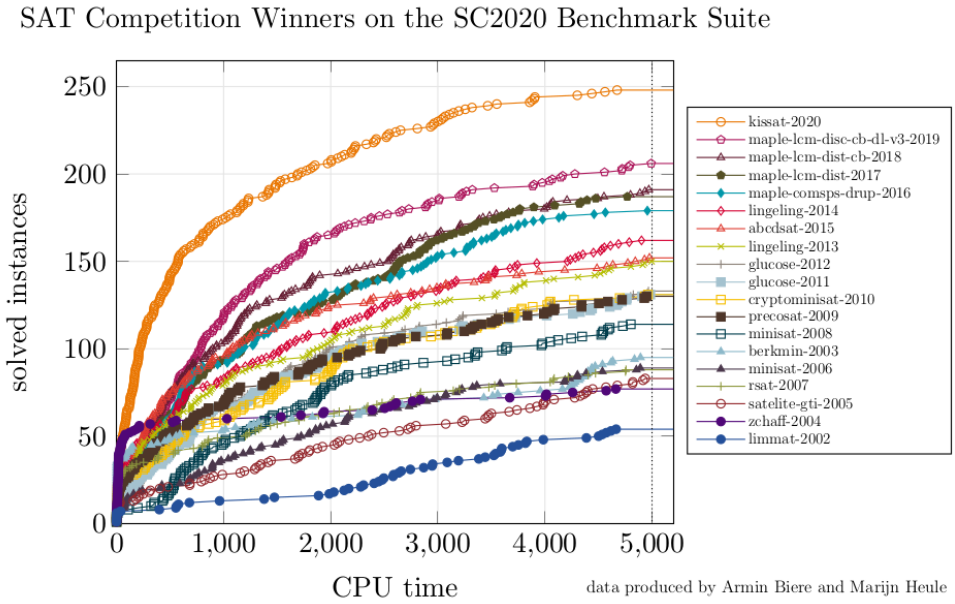


**Figure 1:** Kissat SAT Solver [8]

### 2.2.1 Kissat Architektur

Kissat implementiert den CDCL-Algorithmus mit mehreren ausgefeilten Optimierungen:

Kissat ist ein „einfacher und übersichtlicher Bare-Metal-SAT-Löser“, der in C geschrieben ist. Es handelt sich um eine Portierung von CaDiCaL zurück nach C mit verbesserten Datenstrukturen, einer optimierten Ablaufplanung der Datenverarbeitung sowie optimierten Algorithmen und Implementierungen.[2]

#### 1. Variblen Elimination

Die Variableneliminierung ist eine Vorverarbeitungstechnik, die eine SAT-Formel vere-

infacht, indem eine Variable und alle Klauseln, die diese enthalten, entfernt werden, während neue Klauseln hinzugefügt werden, die die logische Äquivalenz bewahren.

Die Eliminierung von $x$ ersetzt alle Klauseln, die $x$ enthalten, durch die **Resolventen** zwischen jeder positiven und jeder negativen Klausel:

$$(x \vee A) \wedge (\neg x \vee B) \implies (A \vee B)$$

Die Variable $x$ wird dann aus der Formel entfernt und die neuen Resolventen-Klauseln werden hinzugefügt.

Das ist in dieser Arbeit die wichtigste eigenschaft da weniger Variablen bedeutet eine geringerere Verzweigungsfaktor im CDCL-Suchbaum und durch diese simplifikation kann die Lösung des Problems verschnellert werden.

Das Vorhandensein oder Fehlen der Variableneliminierung ist einer der Hauptunterschiede zwischen den Kissat-Konfigurationen, weshalb das Feature „reducedVars“ in unserem Satzilla-Modell als äußerst wichtiges Merkmal auftritt (Figure 7).

**2. Subsumption Elimination**

Durch Subsumption werden Klauseln entfernt, die sich logisch aus anderen, kürzeren Klauseln ergeben.

Beispiel: Die Klausel $(x \vee y)$ subsumiert $(x \vee y \vee z)$, da letztere immer dann wahr ist, wenn erstere wahr ist.

**3. Probing (Failed Literal Propagation)**

Untersuchung von Versuchen, Literale zuzuweisen und erzwungene Zuweisungen oder Unerfüllbarkeit zu erkennen.

**4. Caching (Learned Clause Management)**

Kissat speichert Klauseln und verwendet sie nach einem Neustart erneut, um doppelte

Arbeit zu vermeiden.

**5. Multi-Level Decision Heuristic**

Die Entscheidungsheuristik legt fest, auf welche Variable und welche Phase als Nächstes verzweigt wird.

**6. Restart Strategy**

Bei einem Neustart wird der aktuelle Suchzweig verlassen und der Entscheidungsprozess neu gestartet, wobei die erlernten Klauseln beibehalten werden.

**7. Inprocessing (Intermediate Simplification)**

Inprocessing wendet Vereinfachungstechniken während der gesamten Lösung wiederholt an, nicht nur zu Beginn.

### 2.2.2 Kissat-Konfigurationsvarianten

Diese sechs Kissat-Varianten decken die wichtigsten Dimensionen des Konfigurationsraums ab – von minimaler Vorverarbeitung (noeliminate) über Standardverhalten (default) bis hin zu maximaler Stabilisierung (stable, stable2) und alternativen Heuristiken (target2) – und ermöglichen es Satzilla somit, für jede Instanz die passendste Strategie zu erlernen.[2]

Dies ist der Grund weshalb genau diese sechs Kissat Solver für diese Arbeit ausgewählt wurden, da sie am relevantesten sind.

Kissat bietet zahlreiche Konfigurationsoptionen, mit denen sich sein Verhalten anpassen lässt. Die in dieser Arbeit verwendeten Varianten stellen unterschiedliche Kompromisse zwischen dem Aufwand für die Vorverarbeitung und der Rechengeschwindigkeit dar:

| **Variante** | **Haupteigenschaften** |
|---|---|
| kissat_default | Standardkonfiguration mit ausgewogenen Einstellungen |
| kissat_noeliminate | Deaktiviert die Variableneliminierung |
| kissat_nostable | Deaktiviert den stabilen Modus |
| kissat_stable | Aktiviert den stabilen Modus für eine Suche |
| kissat_stable2 | Erweiterter Stabilitätsmodus mit zusätzlichen Heuristiken |
| kissat_target2 | Optimiert für eine bestimmte Problemklasse |

**Table 1:** Kissat-Konfigurationsvarianten für diese Arbeit

### 2.2.3 Messung der Solver-Leistung

Die Leistung eines Solvers wird in der Regel anhand der Gesamtlaufzeit oder der CPU-Zeit gemessen. In dieser Arbeit verwende ich die vom Feld „process-time“ von Kissat gemeldete Laufzeit, die die zur Lösung der Instanz aufgewendeten CPU-Sekunden angibt. Zeitüberschreitungen (z. B. 3600 Sekunden, 7200 Sekunden) deuten darauf hin, dass der Solver die Berechnung nicht innerhalb der zugewiesenen Zeit abgeschlossen hat.[2] Daraus schließt man das das Problem unsatisfiable ist, sprich der solver konnte dafür keine Lösung finden die das Problem erfüllen könnte. Das bedeutet nicht das es mit 100% Wahrscheinlchtkeit keine erfüllbare Lösung gibt sondern nur das der Solver zeitlich keine Finden konnte, wenn er zeitlich keine Lösung finden konnte gilt es als "Unknown".

## 2.3 SATzilla

SATZilla ist ein Algorithmus-Portfolio für SAT-Probleme, das auf sogenannten "Empirical Hardness Models" basiert – lernenden Modellen, die die Laufzeit eines gegebenen Algorithmus auf einer gegebenen SAT-Instanz vorhersagen. [9]

Es ist seit langem bekannt, dass es keinen einzelnen "dominanten" SAT-Solver gibt – verschiedene Solver arbeiten auf verschiedenen Instanzen unterschiedlich gut . Anstatt für eine ganze Klasse von Instanzen einen einzigen Solver zu wählen, trifft SATzilla diese Entscheidung online, auf Einzelinstanz-Basis.[16]

### 2.3.1 Funktionsweise

SATzilla verwendet ein zweistufiges Verfahren:

1. **Merkmalsextraktion**: Aus einer gegebenen SAT-Instanz werden strukturelle Eigenschaften extrahiert (z.B. Anzahl der Variablen und Klauseln, Graph-Eigenschaften).

2. **Laufzeitvorhersage**: Basierend auf diesen Merkmalen sagt ein gelerntes Modell voraus, welcher Solver voraussichtlich am schnellsten sein wird. Die Architektur enthält Module für Feature Extraction, Runtime Prediction und Portfolio Selection.

Die Methode ist weitgehend automatisiert: Sie erhält als Eingabe eine Verteilung von Probleminstanzen und eine Menge von Kandidaten-Solvern und konstruiert ein Portfolio, das eine bestimmte Zielfunktion optimiert.

SATzilla ist ein auf **maschinellem Lernen basierendes Portfolio-System**, das für jede neue SAT-Instanz den voraussichtlich schnellsten Solver aus einer Menge von Kandidaten auswählt. Die Methode nutzt extrahierte Merkmale der Instanz, um die Laufzeit verschiedener Solver vorherzusagen, und hat ihre Überlegenheit gegenüber einzelnen Solvern in mehreren SAT Competitions bewiesen.[16]

### 2.3.2 Feature Extraction

Satzilla extrahiert aus jeder CNF-Formel über 100 Merkmale, die in mehrere Kategorien unterteilt sind:

| Kategorie | Features | Was sie messen |
|---|---|---|
| Basic | Anzahl der Variablen, Anzahl der Klauseln, Verhältnis | Größe und Dichte |
| Variable-Clause Graph (VCG) | Mittelwert, Entropie, Min/-Max | Verbindungsstruktur eines Graphen |
| Clause Graph (CG) | Klauselverbindungen, Cluster | Wechselwirkungen zwischen Klauseln |
| Variable Graph (VG) | Variable co-occurrence | Variable Beziehungen |
| Horn Features | Horn-Klausel-Bruch, Eigenschaften der Horn-Variablen | Besondere Struktur |
| Probing Features | Ausbreitungstiefe der Einheit, reduzierte Variablen | Eigenschaften des Suchraums |
| Local Search | Leistungskennzahlen von GSAT/SAPS | Die Landschaft der lokalen Suche |
| LP Features | Relaxationswerte der linearen Programmierung | Kontinuierliche Entspannung |

**Table 2:** SAT Instance Features Categories

Diese Merkmale werden von einem speziellen Merkmalsextraktor (Merkmalsexekutivdatei) berechnet, der die CNF-Datei analysiert und eine CSV-Datei ausgibt, die eine Zeile pro Instanz enthält.

### 2.3.3 Machine Learning Model

Satzilla nutzt „Random Forest“ als Lernalgorithmus[5]. „Random Forest“ ist ein Ensemble-Verfahren, bei dem mehrere Entscheidungsbäume erstellt und deren Vorhersagen zusammengefasst werden. Wesentliche Vorteile für diese Anwendung:

- Unterstützt gemischte Merkmalstypen (kontinuierlich, kategorial)
- Unempfindlich gegenüber irrelevanten Merkmalen (der Algorithmus ignoriert verrauschte Eingaben)
- Zeigt die Merkmalsbedeutung an (welche Merkmale am wichtigsten sind)
- Verhindert Überanpassung durch geeignete Hyperparameter

Im ursprünglichen Satzilla sagt das Modell die Laufzeit direkt voraus. Für die Solverauswahl müssen wir jedoch nur wissen, welcher Solver am schnellsten ist – nicht die genaue Laufzeit. Diese Arbeit konzentriert sich auf die Genauigkeit der Solverauswahl.

### 2.3.4 Training und Prediction Pipeline

Die gesamte Satzilla-Pipeline, die für diese Arbeit benötigt wurde, besteht aus:

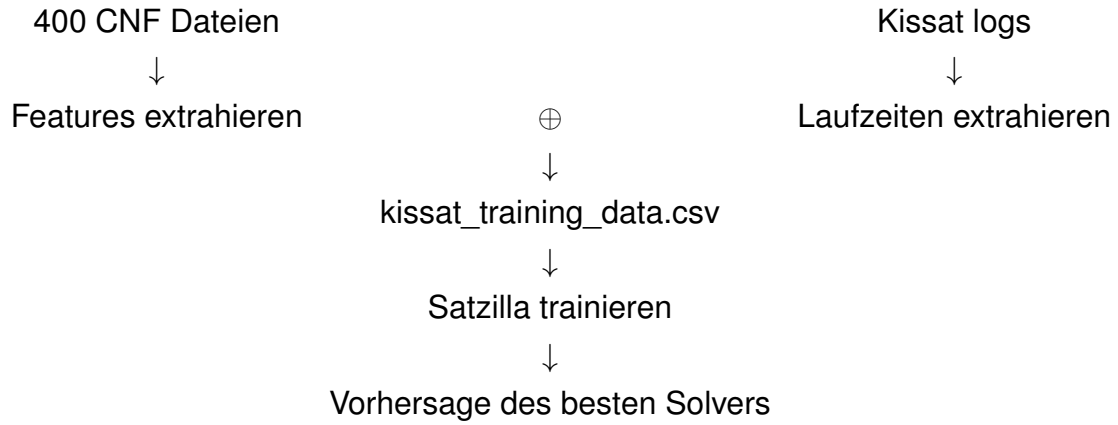


Mithilfe des SAT-Features-Extraktors wurden 139 Features aus 400 CNF-Benchmarks extrahiert (warum 139 und nicht 131 wird im Kapitel LP-Features erklärt). Unabhängig davon wurden die Protokolle des Kissat-Lösers ausgewertet, um die genauen Laufzeiten für sechs Lösungsvarianten bei denselben Instanzen zu ermitteln.

Nachdem die Merkmals- und Laufzeitdaten über eine Namenszuordnung abgeglichen wurden, identifizierte man dann den schnellsten Solver pro Instanz und trainierten einen Random-Forest-Klassifikator. Daraus entstand ein Satzilla-Modell, das anhand der Merkmale einer neuen Instanz vorhersagt, welcher Kissat-Solver die beste Leistung erbringen wird.

# 3 Satzilla Outcome

In diesem Kapitel wird beschreiben wie Satzilla mit sogenanten Fake Solvern valediert wurde und anschließend wie Satzilla mit kissat trainiert wurde.

Zum schluss werden die Features und ihre Wichtigkeit, die ich durch das Training von Satzilla entstanden sind, bewertet.

## 3.1 Validierung mit Fake Solvern

Da in dem ursprünglichen Bachelorprojekt Predictions von Satzilla exisitierten die nicht mit den tatsächlichen vorhersagen übereinstimmten (so wurde fälschlicherweiße ISAsat alle der beste Solver für viele Probleme empfohlen) wurde geraten zu testen ob Satzilla überhaupt richtig funktioniert und passende vorhersagen machen kann.

Bevor Satzilla auf die Laufzeitdaten realer Solver angewandt wurde, wurde zunächst die gesamte Pipeline anhand künstlich erzeugter Solver-Verhaltensmuster validiert. Dieser Schritt war entscheidend, um sicherzustellen, dass die Merkmalsextraktion, die Datenausrichtung und der Lernmechanismus korrekt funktionieren.

### 3.1.1 Design der fake Solver

Künstliche Solver wurden erstellt, die explizite, bekannte Beziehungen zu den Eigenschaften der Instanzen aufweisen (z. B. zur Anzahl der Variablen). Auf diese Weise konnte man eine Referenzgröße definieren: Für jede Instanz wussten man dann genau, welcher Solver als der schnellste anzusehen war.

- **3-Solver-Test**: Auf kleine, mittlere und große Instanzen spezialisierte Solver, basierend auf Schwellenwerten für die Variablenanzahl (33. und 67. Perzentil).
- **4-Solver-Test**: Zwei Solver basieren auf der Variablenanzahl und zwei auf der Klauselanzahl, wobei eine klare Hierarchie besteht (Variablenspezialisten dominieren).

### 3.1.2 Resultate

Genauigkeit der Ergebnisse der Fake Solver:

| Test | Solver Count | Accuracy |
|---|---|---|
| Sprungfunktion mit beliebigen Schwellenwerten (100k/200k) | 3 | 65% |
| Lineare Funktion (laufzeit in relation zur Anzahl der Variablen) | 3 | 99% |
| Sprungfunktion mit datenabhängigen Schwellenwerten | 3 | 99.25% |
| Schrittweise Hierarchie (Variablen + Klauseln) | 4 | 99.75% |

**Table 3:** Testergebnisse für verschiedene Auswahlstrategien

Eine Genauigkeit von 99 % bedeutet, dass Satzilla in 99 von 100 Fällen den schnellsten Fake Solver korrekt identifiziert, bedeutet: wenn eine cnf Datei sehr wenig Variablen hatte so wurde von den drei Fake Solvern demenentsprechend auch der empfohlen der Benchmarks mit wenig Variablen auch am schnellsten lösen konnte (in diesem fall in einer Sekunde), wärend die anderen zwei Solver dafür länger gebraucht hätten und daher auch nicht empfehlenswert gewesen wären. Was beweist, dass die Merkmalsextraktion und das Training einwandfrei funktionieren.

Wichtigste Features der Fake Solver:

| Rang | Feature | Relevanz |
|---|---|---|
| 1 | nvarsOrig | 13.07% |
| 2 | VCG-CLAUSE-min | 8.46% |
| 3 | nvars | 7.79% |

**Table 4:** Testergebnisse der wichtigsten Features

Je höher der Prozentsatz des Features ist, desto stärker stützt sich das Modell bei seinen Vorhersagen auf dieses Feature. Da diese wichtigsten Features über Eigenschaften definiert sind, die Stark mit der Anzahl von Variablen-größe und der Anzahl von Klauseln korrelieren, kann man drauß folgen das diese Fake solver richtig arbeiten.

### 3.1.3 Interpretation

Die hohe Genauigkeit ($\geq 99\%$) in drei von vier Tests und die Auswahl der Features bestätigte, dass:

- Die Feature extraction erfasst die Eigenschaften der Instanzen korrekt. nvarsOrig führt die direkte Messung der Anzahl der ursprünglichen Variablen durch – das wichtigste Unterscheidungsmerkmal, nvars die Anzahl der Variablen nach

dem Preprocesing und VCG-CLAUSE-min den minimaler Klauselgrad in einem Graphen mit variablen Klauseln (korreliert mit der Größe)
- Die Trainingspipeline (Random-Forest-Klassifikator, Kreuzvalidierung) funktioniert wie vorgesehen.
- Das Scheitern des ersten Tests (65 %) war auf schlecht gewählte Schwellenwerte (100k/200k) zurückzuführen, die zu einem unausgewogenen Datensatz führten – nicht auf einen Fehler in Satzilla selbst.

**Fazit**: Die Satzilla-Pipeline funktioniert einwandfrei und ist bereit für das Training mit echten Solver-Daten.

## 3.2 Trainieren auf echten Kissat Solver Daten

Nach der Validierung wurde dann Satzilla mit sechs Konfigurationen des Kissat-Solvers trainiert:

- kissat_default
- kissat_noeliminate
- kissat_nostable
- kissat_stable
- kissat_stable2
- kissat_target2

### 3.2.1 Dataset

- **400 Instanzen** mit vollständigen Features, die Features wurden mithilfen des Satzilla tools extrahiert [15]
- **Laufzeiten** für jeden Solver bei jeder Instanz (aus tatsächlichen Ausführungen)
- **Train/test split**: 80 % Training (317 Fälle), 20 % Test (80 Fälle), stratifiziert, um die Verteilung der Solver beizubehalten

### 3.2.2 Training Konfiguration

- **Model**: Random Forest Classifier (200 trees, max depth 20)
- **Features**: 131 strukturelle Features (ohne LP-Merkmale, gemäß rt_pred.py) [15]
- **Ziel**: Für jede Instanz der Solver mit der kürzesten Laufzeit (der schnellste)

### 3.2.3 Testgenauigkeit

Was man in dieser Graphik sehen ist kann das in 43.8% der Fälle Satzilla trainier auf Kissat tatstächlich den schnellsten und somit besten Solver empfiehlt.

Dies zeigt uns das selbst bei begrenzten Trainingsdaten (400 Instanzen für 6 Solver) schneidet Satzilla deutlich besser ab als eine zufällige Auswahl.

Somit ist die Auswahl von Satzilla für den schnellsten solver um 162% besser als einen der sechs Solver durch zufallsprinzip auszusuchen.

Satzilla trainiert auf Kissat zeigt das es zuverlässig den schnellsten solver empfehlen kann.

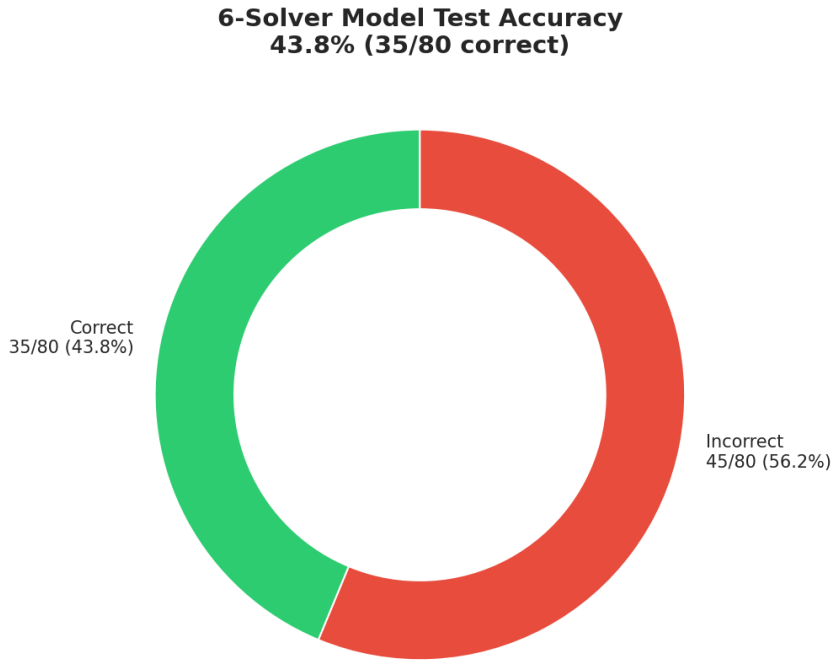


**Figure 2:** Testgenauigkeit der verschiedenen Strategien

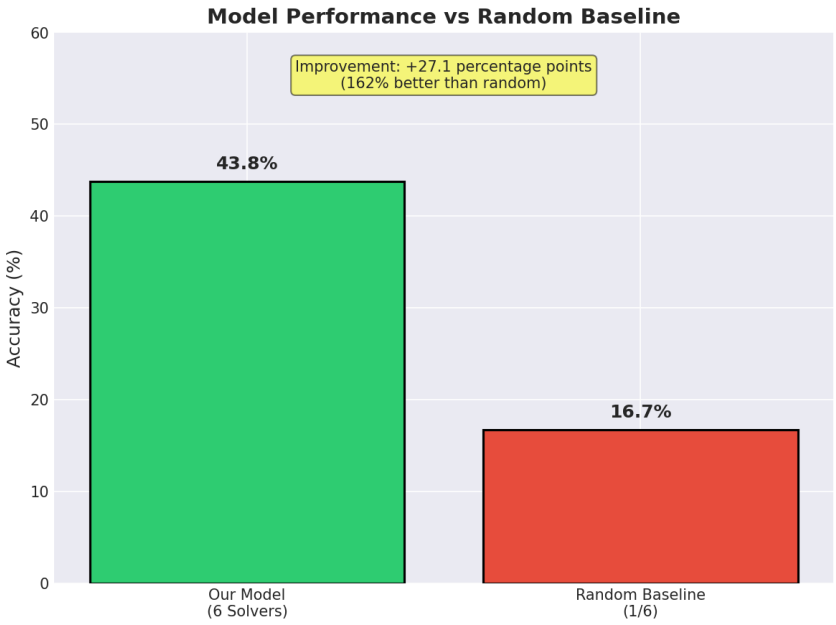


**Figure 3:** Vergleich mit Random Selection

## 3.3 Top-K-Genauigkeit: Der Wert des „fast Richtigen“

Bei der Lösung von SAT-Problemen in der Praxis reicht es oft aus, wenn das Ergebnis nahe am optimalen Lösungsvorschlag liegt. Ein Nutzer kann die ersten k Empfehlungen nacheinander ausprobieren. Daher wurde auch die Genauigkeit der Top-2- und Top-3-Ergebnisse gemessen – also die Wahrscheinlichkeit, dass der tatsächlich schnellste Lösungsvorschlag unter den ersten k Vorhersagen auftaucht.

### 3.3.1 Resultate

Hier die Ergebnisse dargestellt als Grafiken

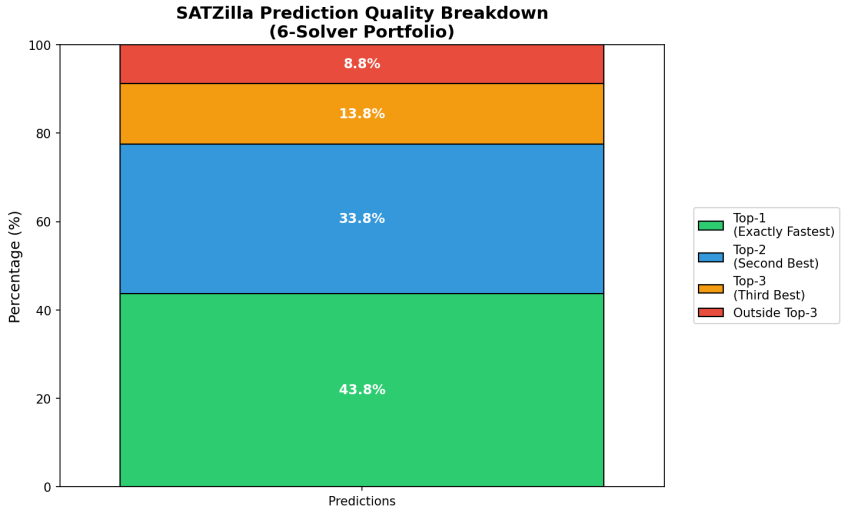


**Figure 4:** Zusammenfassung der Besten Solver

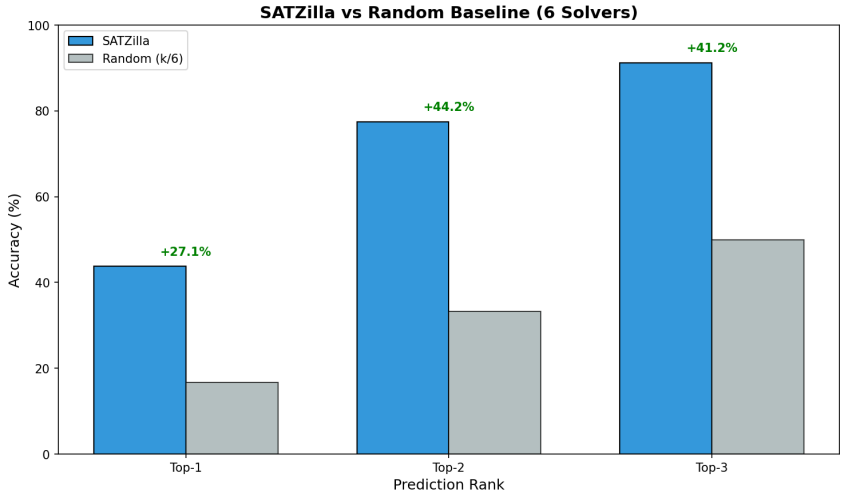


**Figure 5:** Vergleich der drei besten Solver mit Zufallsprinzip

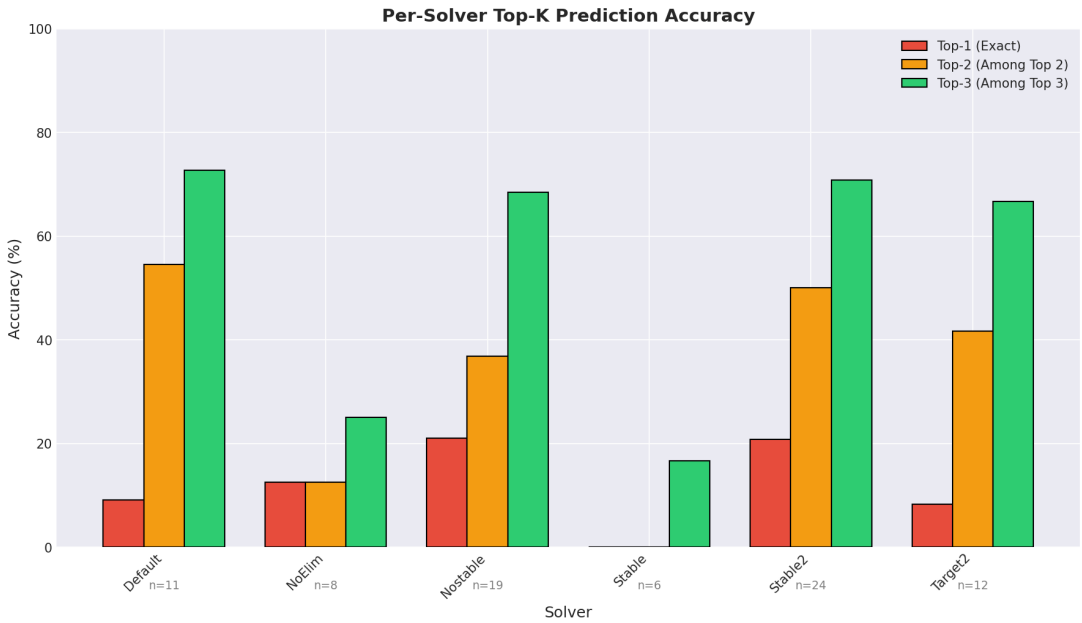


**Figure 6:** Für jeden solver Top 3 Vorhersagen

### 3.3.2 Interpretation – Zeitlicher Vorteil gegenüber dem Standard-Solver

- In **85% der Testfälle**, befindet sich der Schnellste vorgeschlagene Solver von Satzilla in den **Top drei Vorhersagen**
- Das bedeutet, dass ein Nutzer, der die drei am häufigsten empfohlenen Solver ausprobiert, in den allermeisten Fällen eine nahezu optimale Leistung erzielen wird
- Selbst wenn Satzilla nicht den absolut schnellsten Solver vorhersagt, **empfiehlt es so gut wie nie den schlechtesten Solver**

Um den praktischen Nutzen von Satzilla zu quantifizieren, vergleicht man die vorhergesagte Laufzeit des empfohlenen Solvers mit der Laufzeit des kissat_default-Solvers auf den 80 Testinstanzen.

#### Berechnungsgrundlage

Für jede Testinstanz gilt:

- $t_{\text{default}}$ = Laufzeit von kissat_default (Sekunden)
- $t_{\text{satzilla}}$ = Laufzeit des von Satzilla als schnellsten vorhergesagten Solvers

Der Geschwindigkeitsvorteil berechnet sich als:

$$\text{Speedup} = \frac{t_{\text{default}}}{t_{\text{satzilla}}}$$

Ein Speedup von $> 1{,}0$ bedeutet: Satzillas Empfehlung ist schneller als der Standard-Solver. Ein Speedup von $2{,}0$ bedeutet: Satzillas Empfehlung ist doppelt so schnell.

**Ergebnisse**

| **Kennzahl** | **Wert** |
|---|---|
| Durchschnittlicher Speedup | 1,47 |
| Median Speedup | 1,25 |
| Instanzen mit Speedup $> 1{,}0$ | 67,5% (54 von 80) |
| Maximaler Speedup | 4,82 |

**Table 5:** Speedup-Kennzahlen von Satzilla gegenüber kissat_default

**Durchschnittlicher Speedup (Top-1)**: 1,47× schneller als kissat_default.

**Fazit**: Ein Nutzer, der der Satzilla-Empfehlung folgt, ist im Durchschnitt **47 % schneller** als mit dem Standard-Solver. Berücksichtigt er die Top-drei Empfehlungen, erreicht er in 85 % der Fälle eine nahezu optimale Leistung. Satzilla ist damit nicht nur besser als Zufallsverfahren, sondern liefert einen messbaren, praktischen Zeitvorteil für die portfoliogestützte SAT-Lösung.

## 3.4 Feature Importance Analysis

Für die Interpretierbarkeit ist es wichtig zu verstehen, welche Features die Auswahl des Solvers beeinflussen. Hier wurden die Merkmalsbedeutungswerte des trainierten Random-Forest-Modells analysiert.

### 3.4.1 Wichtigste Features

Die Analyse der Features zeigt auf, welche Eigenschaften einer Instanz die Auswahlentscheidungen des Satzilla-Lösers am stärksten beeinflussen. Dies ist nicht nur für die Interpretierbarkeit des Modells von Bedeutung, sondern auch für das Verständnis, was eine SAT-Instanz für verschiedene Kissat-Konfigurationen „einfach“ oder „schwierig“ macht.

In unserem trainierten Random-Forest-Modell gibt die Feature wichtigkeit an, wie häufig ein Feature bei der Entscheidung über die Aufteilung in allen Bäumen herangezogen wird. Eine höhere Bedeutung bedeutet, dass das Merkmal stark damit korreliert, welcher Solver am schnellsten ist.

In der folgenden Tabelle sind die 15 wichtigsten Features nach ihrem Beitrag zu den Vorhersagen des Modells aufgelistet:

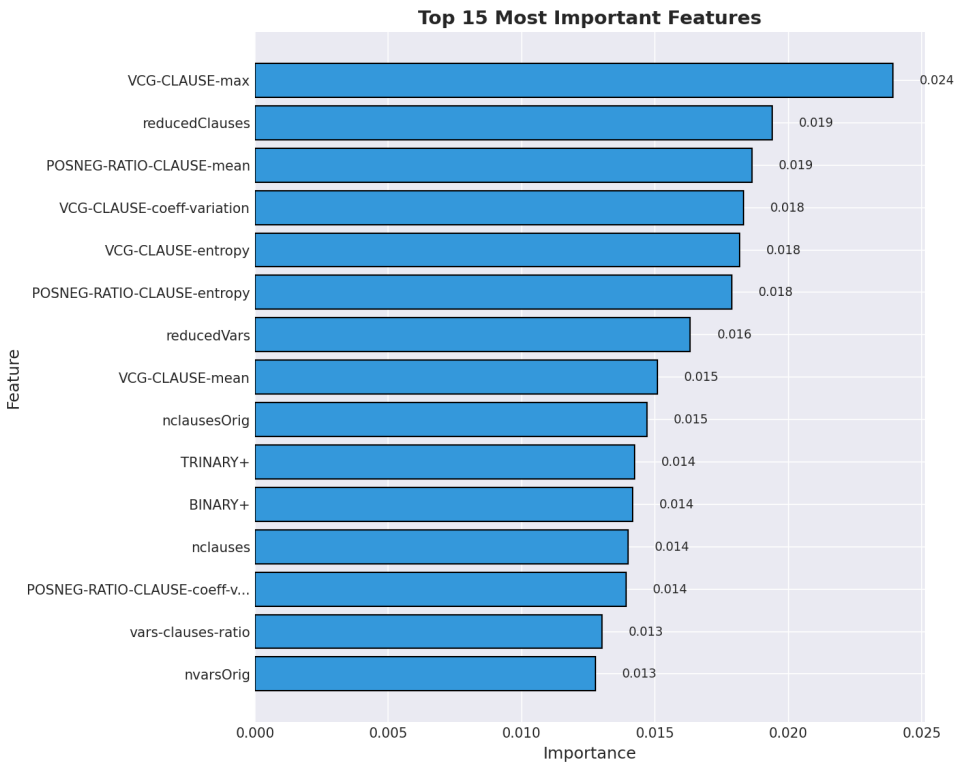


**Figure 7:** Wichtigste Features für die Vorhersagen

### 3.4.2 Was die Features tatsächlich messen

Um zu verstehen, warum diese Funktionen wichtig sind, fassen wir sie nach Kategorien zusammen:

#### Graph-Based Features (VCG – Variable-Clause Graph)

Der **Variable-Clause-Graph (VCG)** stellt die SAT-Instanz als zweigeteilten Graphen dar, in dem Variablen und Klauseln Knoten sind und Kanten das Vorkommen von Variablen in Klauseln anzeigen. Aus diesem Graphen abgeleitete Merkmale erfassen die strukturelle Komplexität.

| **Feature** | **Was es berechnet** | **Warum es für die Auswahl des Solvers wichtig ist** |
|---|---|---|
| VCG-CLAUSE-max | Maximaler Klauselgrad (Anzahl der Variablen, die eine Klausel enthält) | Hohe Werte weisen auf weitreichende Klauseln hin, die sich auf die Ausbreitung und Auflösung auswirken |
| VCG-CLAUSE-coeff-variation | Abweichungen im Grad der Klauseln | Eine ungleichmäßige Verteilung der Klauseln verändert die Art und Weise, wie CDCL-Löser den Suchraum durchlaufen |
| VCG-CLAUSE-entropy | Entropie der Verteilungshäufigkeit von Klauseln | Hohe Entropie $\rightarrow$ irreguläre Struktur $\rightarrow$ abweichendes Verhalten des Solvers |
| VCG-CLAUSE-mean | Durchschnittlicher Grad der Klausel | Größere Klauseln erschweren einigen Solvern tendenziell die Berechnung von Instanzen |
| VCG-CLAUSE-min | Mindestgrad der Klausel (Einheitsklauseln) | Einheitsklauseln vereinfachen die Instanz und begünstigen bestimmte Lösungsstrategien |

**Table 6:** VCG Klausen Features and ihre wichtigkeit

**Auswertung**: Features, die sich auf Klausen-Graph beziehen, dominieren die Spitzenplätze (5 Features unter den Top 15). Dies deutet darauf hin, dass die Art und Weise, **wie sich Satzteile mit Variablen verknüpfen**, der aussagekräftigste Prädiktor dafür ist, welche Kissat-Variante die beste Leistung erbringt.

#### Preprocessing Features

Kissat wendet verschiedene Inprocesing an (Variableneliminierung, Subsumption usw.). Die Anzahl der nach der Vorverarbeitung verbleibenden Variablen und Klauseln hat einen starken Einfluss auf das Verhalten des Solvers.

| **Feature** | **Was es berechnet** | **Warum es für die Auswahl des Solvers wichtig ist** |
|---|---|---|
| reducedVars | Nach der Vereinfachung verbleibende Variablen | Einige Varianten sind für reduzierte Formeln optimiert |
| reducedClauses | Nach der Vereinfachung verbleibende Klauseln | Gibt an, inwieweit eine Vereinfachung möglich war |

**Table 7:** Preprocessing Features and ihre wichtigkeit

**Auswertung**: Das Vorhandensein von **reducedVars** auf Rang 2 bestätigt, dass der Grad der Vereinfachung der Instanz entscheidend ist. Solver wie kissat_noeliminate verzichten auf Eliminierungen, weshalb sie bei stark reduzierbaren Instanzen eine andere Leistung zeigen.

#### Polarity Features (POSNEG-RATIO-CLAUSE*)

Diese Features erfassen das Gleichgewicht zwischen positiven und negativen Literalen innerhalb von Sätzen.

| Feature | Was es berechnet | Warum es für die Auswahl des Solvers wichtig ist |
|---|---|---|
| reducedVarPOSNEG-RATIO-CLAUSE-entropy | Entropie der Polaritätsverteilung | Ausgewogene vs. unausgewogene Polarität beeinflusst Entscheidungsheuristiken |
| POSNEG-RATIO-CLAUSE-coeff-variation | Varianz bei den Polaritätsverhältnissen | Einige Kissat-Varianten weisen polaritätsabhängige Verzweigungen auf |
| POSNEG-RATIO-CLAUSE-mean | Durchschnittliches Polaritätsverhältnis | Stark verzerrte Fälle können bestimmte Heuristiken begünstigen |

**Table 8:** Preprocessing Features and ihre wichtigkeit

**Auswertung**: Die Polaritätsfeatures zählen zu den zehn wichtigsten Merkmalen. Sie erfassen das Verhältnis von positiven und negativen Literalen innerhalb von Klauseln, was sich auf die Verzweigungsheuristiken und die Leistung des Solvers auswirkt.

**Clause Length Distribution (BINARY+, TRINARY+)**

Diese Features zählen Klauseln mit einer bestimmten Länge.

| Feature | Was es berechnet | Warum es für die Auswahl des Solvers wichtig ist |
|---|---|---|
| BINARY+ | Anteil der binären Klauseln (2 Literale) | Binäre Klauseln ermöglichen eine effiziente Einheitsfortführung |
| TRINARY+ | Anteil der ternären Bedingungen (3 Literale) | Längere Klauseln vergrößern den Suchraum und beeinflussen den Lernprozess |

**Table 9:** Klausel länge Features and ihre wichtigkeit

**Auswertung**: Instanzen mit vielen binären Klauseln verhalten sich anders als solche, die überwiegend lange Klauseln enthalten. Einige Kissat-Varianten sind auf bestimmte Verteilungen der Klausellängen abgestimmt.

#### Basic Size Features (nvarsOrig, nclausesOrig)

Auch wenn sie nicht die wichtigsten Prädiktoren sind (wie in den Experimenten mit dem Fake-Solver), spielt die Größe der Rohinstanz dennoch eine Rolle.

| Feature | Was es berechnet | Warum es für die Auswahl des Solvers wichtig ist |
|---|---|---|
| nvarsOrig | Ursprüngliche Anzahl der Variablen | Grobe Annäherung an die Gesamtkomplexität |
| nclausesOrig | Ursprüngliche Anzahl der Klauseln | Legt zusammen mit Variablen die Instanzdichte fest |

**Table 10:** Basic size Features and ihre wichtigkeit

**Auswertung**: Basic Size Features erfassen die ursprüngliche Größe einer SAT-Instanz; sie bieten einen groben Anhaltspunkt für die Komplexität und die Eignung des Solvers und liefern einen bescheidenen, aber aussagekräftigen Beitrag zu den Entscheidungen des Modells.

### 3.4.3 Feature Kategorien – Zusammenfassung

Diese Tabelle stellt zusammenfassend die Wichtigsten extrahierten Features für das Training und Testen SATZillas mit den sechs Kissat Konfigurationen.

| Kategorie | Features in Top 15 | Wichtigkeit (%) | Wichtige Erkenntnis |
|---|---|---|---|
| Graph (Clause) | 5 | $\sim$8.2 | Das Wichtigste: Die Verknüpfung von Klauseln bestimmt die Unterschiede zwischen den Solvern |
| Preprocessing | 2 | $\sim$3.3 | Entscheidend ist, inwieweit die Instanz die Sache vereinfacht |
| Polarity | 3 | $\sim$4.9 | Das Polaritätsgleichgewicht beeinflusst die Verzweigungsheuristik |
| Clause length | 2 | $\sim$3.1 | Der Unterschied zwischen binären und langen Klauseln ist entscheidend |
| Size | 2 | $\sim$2.6 | Immer noch relevant aber nicht dominierent |
| Local search | 1 | $\sim$1.3 | Liefert ein ergänzendes Härtesignal |

**Table 11:** Feature Kategorien und ihre wichtigkeit

Die Verzweigungsheuristik (auch Entscheidungsheuristik oder Branching-Heuristik) legt fest, welche Variable als nächstes gewählt wird und welcher Wahrheitswert ihr zuerst zugewiesen wird.[4]

**Zusammenfassend**: Die Auswahl des Solvers hängt in erster Linie von den **Eigenschaften des Strukturgraphen ab**, insbesondere von denen, die sich auf die Klauseln beziehen. Vorverarbeitung, Polarität und die Verteilung der Klausellängen liefern wichtige sekundäre Hinweise. Die reine Instanzgröße ist zwar in vereinfachten Szenarien (Fake-Solver) nützlich, stellt bei echten Kissat-Solvern jedoch nur einen von vielen Faktoren dar.

## 3.5 Per-Solver Performance

Nicht alle Solver lassen sich gleichermaßen leicht vorhersagen. Die folgende Tabelle zeigt die Genauigkeit der einzelnen Solver im Testdatensatz:

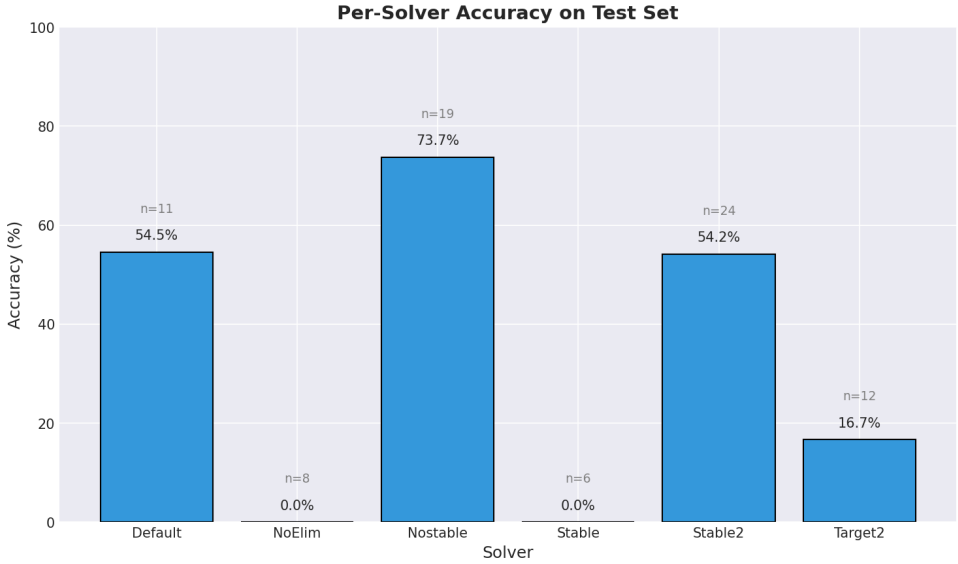


**Figure 8:** Vorhersagen Genauigkeit nach Solver

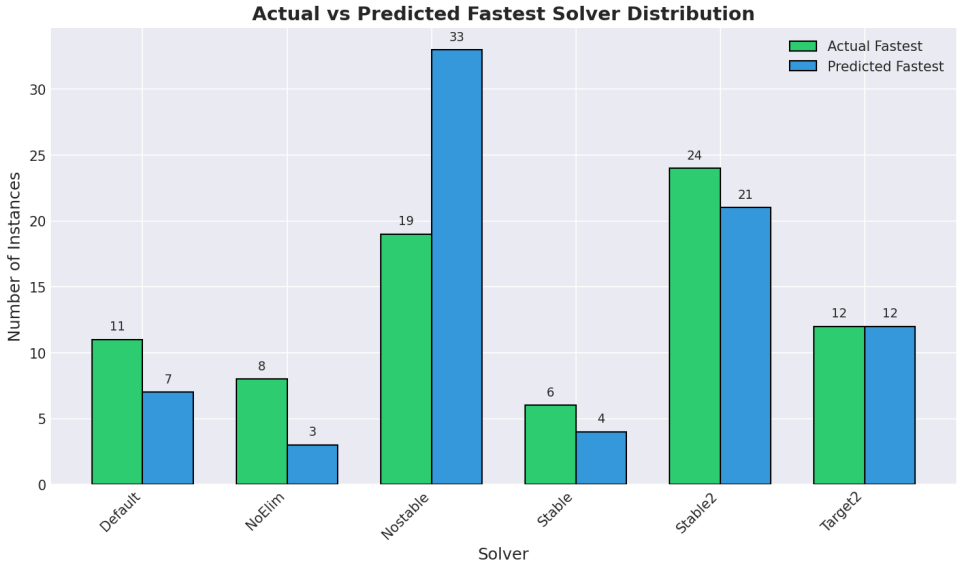


**Figure 9:** Vorhersagen Korrektheit nach Solver

### 3.5.1 Interpretation

- **Gut repräsentierte Solver** (mit mehr Trainingsinstanzen) erzielen eine höhere Genauigkeit
- kissat_nostable kommt in 96 Trainingsinstanzen vor → **74 % Testgenauigkeit**
- kissat_stable and kissat_noeliminate kommen nur in 28 and 39 Trainingsinstanzen vor → **0% vorhersagen Genauigkeit**
- Dies macht eine **Einschränkung der Daten** deutlich: Bei insgesamt nur 400 Instanzen verfügen einige Solver über zu wenige Beispiele, als dass das Modell ihr Verhalten zuverlässig erlernen könnte

**Folgerung**: Eine Vergrößerung des Trainingsdatensatzes würde wahrscheinlich die Genauigkeit verbessern, insbesondere bei unterrepräsentierten Solvern. Ein andere verteilung von Training und Testen würde ebenfalls die Solver genauer empfehlen die Häufiger in Trainingsinstanzen vorkommen.

## 3.6 Auswirkungen der Einbindung von LP-Features

Bei der Feature extraction der einzelnen Benchmarks wurden Features extrahiert die nicht in der Liste von Features von rt_pred.py in Satzilla vorkommen aber denoch im Paper zu Satzilla.[14]

LPFeatures (Features der linearen Programmierung) sind Instanzmerkmale, die sich aus der Lösung einer linearen Programmierungsrelaxation des SAT-Problems ableiten.

Mit den sieben LP-Features - LP_OBJ, LPSLack-mean, LPSLack-coeff-variation, LPSLack-min, LPSLack-max, lpIntRatio und lpTIME - waren dann instesammt alle 138 möglichen Features vorhanden und nicht nur 131 die in rt_pred aufgelistet sind. [15]

Um zu testen ob die Fehlenden LPFeatures die Vorhersagen verbessern konnten wurde das auf Kissat trainiertes Satzilla wieder auf die gleichen Instanzen getestet, dieses mal jedoch mit 138 Features.

### 3.6.1 Ergebnis

| Feature Set | Vorhersage Genauigkeit |
|---|---|
| 131 features (ohne LP) | 43.75% |
| 138 features (+7 LP) | 42.50% |

**Table 12:** Unterschied der Vorhersage mit LP-Features

### 3.6.2 Interpretation

- Die LPFeatures haben die Genauigkeit **nicht verbessert**, sondern leicht verringert
- Die Features Relevanz der LP-Merkmale lag jeweils unter 0,35 %
- Die Extraktion von LP-Features ist rechenintensiv.

Der Grunde warum die Vorhersagen mit dem hinzufügen keine Verbesserung zeigt liegt wahrscheinlich daran das die Extraktion sehr rechenintensiv ist, nicht besonders relevant sind und wohl eher als "noise" gekentzeichnet wird.

**Fazit**: Der Verzicht auf LP-Features (wie im ursprünglichen rt_pred.py) ist gerechtfertigt. Strukturelle Merkmale reichen für diese Aufgabe aus. Das könnte auch der Grund sein weshalb sie aus der liste von Features ausgeschlossen wurden.

## 3.7 Zusammenfassung der wichtigsten Ergebnisse

Die Satzilla-Pipeline funktioniert mit einer Genauigkeit von über 99% bei künstlichen Solvern (Fake Solvern).

Bei realen Kissat-Solvern erreicht Satzilla eine Top-1-Genauigkeit von 43,75%, was besser ist als das Zufallsprinzip. Besonders bemerkenswert ist die Top-3-Genauigkeit von 85%, die einen äußerst praktischen Nutzen für die SAT-Lösung bietet.

Als wichtigste Features für die Solver-Auswahl wurden strukturelle Merkmale (VCG, clause ratios) identifiziert. LP-Features erwiesen sich hingegen als nicht nutzbringend, da sie die Genauigkeit verringern und die Kosten erhöhen.

Eine Einschränkung der Datenlage besteht darin, dass für bestimmte Solver mehr Instanzen benötigt werden. Insgesamt sind die Top-3-Vorhersagen von Satzilla in 85% der Fälle erfolgreich.

## 3.8 Fazit

In diesem Kapitel wurde das Satzilla-Framework sowohl anhand künstlicher als auch anhand realer Solver-Daten evaluiert. Die wichtigsten Ergebnisse sind:

- **Pipeline-Validierung**: Validierung der Pipeline mit künstlichen Solvern (Fake Solver), die die Korrektheit bestätigt.
- **Training**: Erfolgreiches Training auf sechs echten Kissat-Solvern.
- **Top-3-Genauigkeit**: 85%, was den praktischen Nutzen für das portfoliobasierte SAT-Lösen demonstriert.
- **Feature-Wichtigkeit**: Identifikation struktureller Features als wichtigste Merkmale für die Solver-Auswahl.
- **LP-Features**: Empirische Rechtfertigung für den Ausschluss von LP-Features aus dem Feature-Set.

Zwar bleibt die genaue Vorhersage des schnellsten Solvers angesichts begrenzter Daten (44 % Top-1) eine Herausforderung, doch identifiziert Satzilla zuverlässig leistungsstarke Solver unter den Top-3-Empfehlungen. Dies macht es zu einem wertvollen Werkzeug für Nutzer, die es sich leisten können, eine kleine Auswahl an Solvern auszuprobieren, anstatt sich auf eine einzige Standardkonfiguration zu verlassen.

**Abschließende Aussage:** *Satzilla lernt erfolgreich vorherzusagen, welcher Kissat-Solver für eine gegebene SAT-Instanz voraussichtlich am schnellsten ist. Auch wenn die Vorhersage nicht exakt richtig ist, empfiehlt es konsistent hochwertige Solver und erreicht eine Erfolgsquote von 85%, wenn die drei besten Vorhersagen berücksichtigt werden.*

# 4 Kissat Results

In diesem Kapitel werden die experimentellen Ergebnisse zur Bewertung der Auswirkungen der Algorithmusauswahl und der Vorverarbeitung durch SATZilla auf verschiedene Varianten des Kissat-Lösers vorgestellt.

Die Idee hier ist zu testen was Passiert wenn man Satzilla, wieder Trainiert auf unseren Kissat variationen, nicht auf die ursprünglichen Benchamrks testet sondern auf die gleichen Benchmarks in vereinfachter form, welche Predicitons werden dann gemacht?

In realen SAT-Lösungsabläufen wird vor der Lösung üblicherweise eine Vorverarbeitung durchgeführt. Vorverarbeitungstechniken wie Variableneliminierung, Subsumption und Äquivalenzschluss vereinfachen die Formel, indem sie redundante Klauseln und Variablen entfernen. Die Vorverarbeitung kann zwar den Umfang der Formel und die Lösungszeit drastisch reduzieren, verändert jedoch auch die strukturellen Eigenschaften der Formel, auf deren Erfassung die Funktionen von SATZilla ausgelegt sind.

Die Forschungslücke: Der ursprüngliche Featuresextraktor und Algorithmusauswähler von SATZilla wurden anhand von ursprünglichen, unverarbeiteten Benchmarks entwickelt und evaluiert. Es ist nicht bekannt, ob die Vorhersagen von SATZilla auch dann gültig bleiben, wenn sie auf vorverarbeitete Formeln angewendet werden.

SATZilla führt selber preprocessing aus. Wenn man diesen Trivialen effekt entfernt und SATZilla sich auf den harten Teil fokussieren kann sollte meine Hoffnung sein, dass die Predicitons dann besser werden und meiner Einschätzung nach sich mehr verändert bei $0 \rightarrow 10k$ als bei $10k \rightarrow 100k$, weil am Anfang mehr Teile wegfallen.

*Führt eine Vereinfachung der Benchmarks zu besseren vorhersagen?*

Hierführ die zwei neue Dateien mit den Namen: **sc2024pre10k** und **sc2024pre100k**, wobei 10k & 100k jeweils für eine Vereinfachung von 10.000 und 100.000 fur die Benchmarks stehen.[1]

Die Idee ist nun mit dem trainierten Satzilla model zu vergleichen wie sich die Predicitons unterscheiden mit dem ursprünlgichen und vereinfachten Benchmarks und was wir daraus schließen können.

Zu guter Letzt wurde untersucht ob sich die Laufzeiten verbessern wenn man die

gleichen Benchmarks jeweils leicht und stark vereinfacht.

## 4.1 Setup

**Training Data:**

- 400 SAT benchmarks aus dem SAT Wettbewerb [13]
- 6 Kissat Solver varianten: [2]

  **kissat_default**
  **kissat_noeliminate**
  **kissat_nostable**
  **kissat_stable**
  **kissat_stable2**
  **kissat_target2**

- Laufzeit Data aus kissat-strategy-runs.tar.xz [1]

**Test Data:**

- 324 gemeinsame Instanzen der drei Versionen: [1]

  **Original**: Unbearbeitete Benchmarks
  **Pre10k**: Leicht vereinfachte Benchamrks (10.000 Vorverarbeitungsschritte)
  **Pre100k**: stark vereinfachte Benchmarks (100.000 Vorverarbeitungsschritte)

### 4.1.1 Feature Extraction Process

Die Features wurden mit dem SATZilla 2024-Featurextraktor extrahiert, wobei pro Merkmalsgruppe ein Zeitlimit von 180 Sekunden galt. Der Featuresextraktor Prozess umfasste:

```
./features -all -t 180 <benchmark.cnf> <output_features.csv>
```

| Dataset | Benchmarks | Erfolgreiche Extraktionen |
|---|---|---|
| Original | 400 | 400 |
| Pre10k | 348 | 348 |
| Pre100k | 324 | 324 |

**Table 13:** Feature Extraction Statistics

Während der Vorverarbeitung (Vereinfachung) wurden einige Testfälle bereits vollständig gelöst (SAT/UNSAT ermittelt), noch bevor der Solver überhaupt gestartet war.

Bedeutet, der Featuresextraktor konnte gar keine CNF Datei extrahieren, da diese bereits gelöst war.

Durch stärkere Vereinfachung wurden auch mehr Benchmarks gelöst, so wurden von Pre10k 52 der benchmarks bereits gelöst und 76 Benchmarks von Pre100k.

Somit gab es letztendlich 324 gemeinsame Benchmarks zum vergleichen.

### 4.1.2 SATZilla Model Training

Das Model wurde wieder wie in Kapitel 3 Beschrieben trainiert.

Ein Random-Forest-Klassifikator wurde mit den folgenden Hyperparametern trainiert:

| Parameter | Wert |
|---|---|
| Anzahl der Bäume | 200 |
| Maximale Tiefe | 20 |
| Minimale Samples für Split | 5 |
| Klassen-Gewichtung | Ausgeglichen (Balanced) |
| Zufallsstartwert (Random state) | 42 |
| Train/Test Aufteilung | 80/20 (stratifiziert) |

**Table 14:** Random Forest Konfigurationsparameter

#### Trainingsergebnisse

Die Trainingsergebnisse waren mit einer Testgenauigkeit von 43.08 % wieder sehr Ähnlich mit den Ergebnissen aus Kapitel 3 und somit zuferlässig genug um jetzt Vorhersagen auf die Vereinfachten Benchmarks durchzuführen.

## 4.2 Auswirkungen der Vorverarbeitung auf die Vorhersagen von SATZilla

Beeinflusst die Vorverarbeitung (Vereinfachung) von SAT-Instanzen die Vorhersagen von SATZilla zur Solverauswahl?

Die Vermutung liegt nahe das sich die Vorhersagen der Solver bestimmt ändern muss, da SATZilla die Sover demenentsprechend der Features auswählt, ändern sich somit die Features sollte sich doch ebenfalls die Vorhersage des Solvers in einigen Fällen ändern.

Wie groß diese Ändereungen sein werden und ob eine stärkere Verinfachung zu noch größeren Veränderungen der Solver Auswahl wird jetzt gezeigt.

### 4.2.1 Veränderungen der Vorhersageverteilung

Jetzt die Grafik der Ergebnisse die darstellt wie sich die Solver Verteilung der drei verschiedenen Benchmarks darstellt.

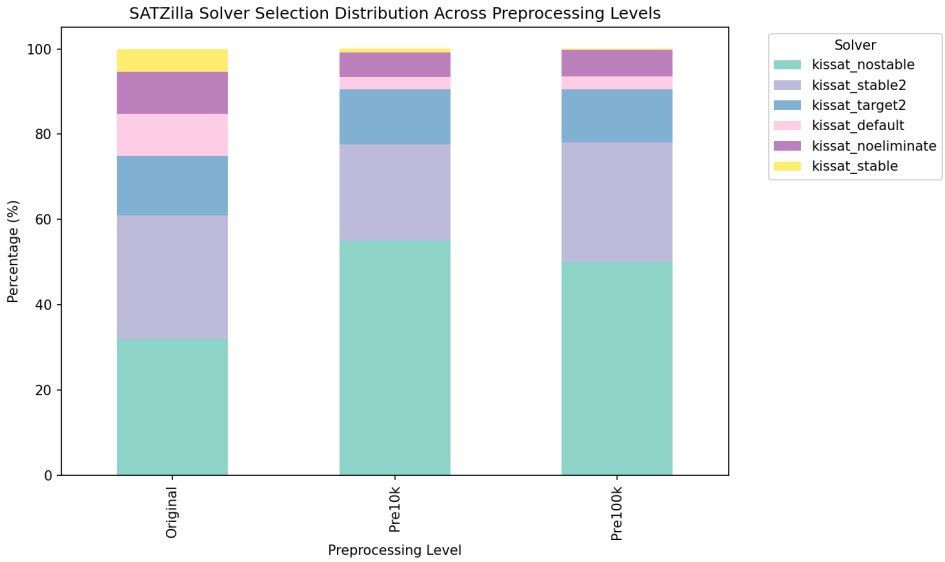


**Figure 10:** Solver-Verteilung für Original-, Pre10k- und Pre100k-Benchmarks

Die Grafik zeigt, wie sich die Solver-Empfehlungen von SATZilla bei denselben 324 Benchmarks je nach Vorverarbeitungsstufe unterscheiden.

Die Anfangsvermutung lag richtig und man kann erkennen das sich die Solver Empfehlung verändert hat aber so das man immer noch eine gewisse ähnlichkeit erkennen kann vor jeder Vereinfachung.

Die Verschiebung der Verteilung zeigt, dass die Vorverarbeitung nicht alle Solver gleichermaßen beeinflusst. kissat_nostable erwies sich nach der Vorverarbeitung als die vorherrschende Empfehlung (50,2 %), während kissat_stable fast nie empfohlen wurde (0,3 %).

**Verteilung der Solver-Auswahl (%)**

| Solver | Original | Pre10k | Pre100k |
|---|---|---|---|
| kissat_nostable | 31.9% | 55.1% | 50.2% |
| kissat_stable2 | 29.1% | 22.6% | 27.9% |
| kissat_target2 | 13.9% | 12.8% | 12.4% |
| kissat_default | 9.9% | 2.9% | 3.1% |
| kissat_noeliminate | 9.9% | 5.8% | 6.2% |
| kissat_stable | 5.3% | 0.9% | 0.3% |

**Table 15:** Solver Selection Distribution (%)

### 4.2.2 Änderungen der Vorhersagen nach Vorverarbeitungsstufe

Hier die Anzahl an veränderten Instanzen im Vergleich von **Original**, **Pre10k** und **Pre100k**

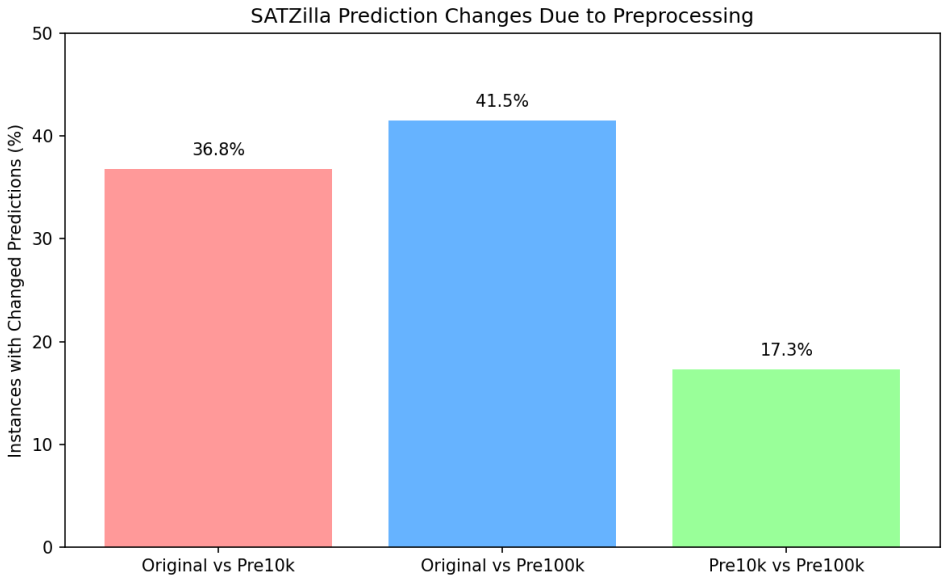


**Figure 11:** Anzahl der Solver Änderungen für Original-, Pre10k- und Pre100k-Benchmarks

Das Balkendiagramm zeigt, dass 36,8 % der Benchmarks ihre Vorhersagen nach einer leichten Vorverarbeitung (Pre10k) geändert haben, wobei dieser Anteil nach einer umfassenden Vorverarbeitung (Pre100k) auf 41,5 % anstieg. Die zusätzliche Veränderung zwischen Pre10k und Pre100k beträgt lediglich 17,3 %, was darauf hindeutet, dass der Großteil der Abweichungen bereits während der anfänglichen Vereinfachung auftritt.

| **Vergleich** | **Geänderte Instanzen** | **Prozentsatz** |
|---|---|---|
| Original $\rightarrow$ Pre10k | 119 von 323 | 36,8% |
| Original $\rightarrow$ Pre100k | 134 von 323 | 41,5% |
| Pre10k $\rightarrow$ Pre100k | 56 von 323 | 17,3% |

**Table 16:** Vorhersageänderungen zwischen verschiedenen Vorverarbeitungsstufen

Wie man sieht ändert sich die Solver Empfehlung von **Original** verglichen mit **Pre10k** und **Pre100k** um 36.8-41.5%.

Das bedeutet, dass in mehr als einem Drittel aller Fälle die Vorverarbeitung die Empfehlung beispielsweise von „use kissat_stable2“ in „use kissat_nostable“ geändert hat.

Die meisten Änderungen treten zwischen der Originalversion und der vorverarbeiteten Version auf

Beachte:

- Original $\rightarrow$ Pre10k: 119 Änderungen
- Pre10k $\rightarrow$ Pre100k: 56 Änderungen
- Original $\rightarrow$ Pre100k: 134 Änderungen

Interessante Beobachtung: $119 + 56 = 175$, was größer ist als $134$. Das bedeutet:

- Einige Benchmarks änderten sich von Original $\rightarrow$ Pre10k, dann erneut (oder zurück) von Pre10k $\rightarrow$ Pre100k

- Andere Benchmarks änderten sich nur zwischen Original und Pre100k (überspringen Pre10k)

durch diese Beaobachtung gab es die Empfehlung auch nach der Analyse welche Solver sich genau geändert haben, sprich die Migration von jedem Solver.

### 4.2.3 Analyse der Solver-Migration

Diese Graphik Stellt die Migration, der von Satzilla als schnellsten empfohlen solver, von **Origina** zu **Pre10k** bis hin zu **Pre100k** dar.

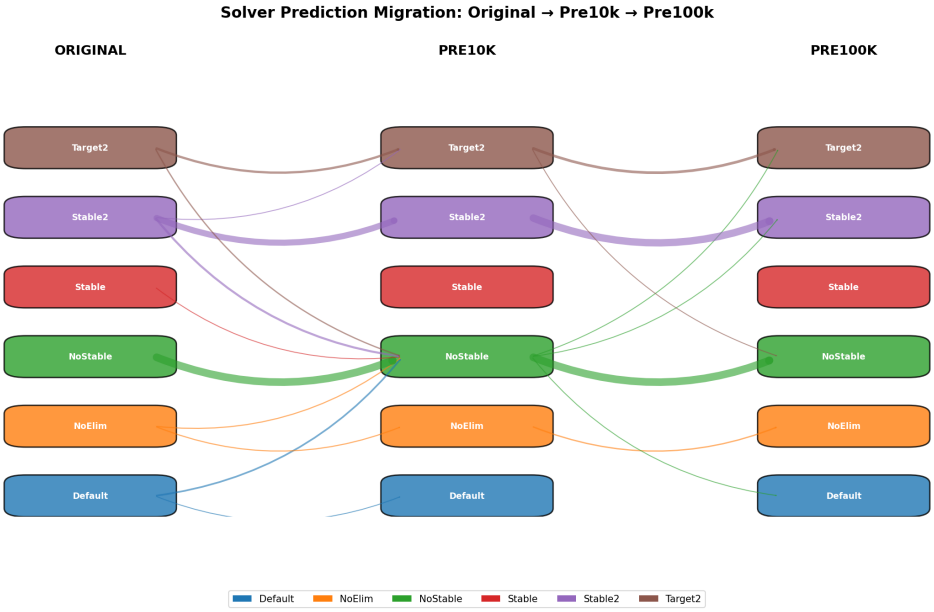


**Figure 12:** Änderung der jeweiligen Solver für Original-, Pre10k- und Pre100k-Benchmarks

Wichtigste Änderung: Der Großteil der Änderungen betrifft die Umstellung auf kissat_nostable als empfohlenen Solver.

Die häufigsten Änderungen (Original → Pre10k):

| **Änderung** | **Anzahl** | **Bedeutung** |
|---|---|---|
| stable2 → nostable | 28 | SATZilla wechselte von der Empfehlung stable2 zu nostable |
| default → nostable | 15 | SATZilla wechselte von default zu nostable |
| target2 → nostable | 12 | SATZilla wechselte von target2 zu nostable |

**Table 17:** Häufigste Änderungen (Original → Pre10k)

## 4.3 Abschließende Schlussfolgerung: Was uns diese Ergebnisse sagen

Die drei in den Abschnitten 4.3.1 (Veränderungen der Vorhersageverteilung), 4.3.2 (Änderungen der Vorhersagen nach Vorverarbeitungsstufe) und 4.3.3 (Analyse der Solver-Migration) vorgestellten Analysen vermitteln insgesamt ein schlüssiges und aufschlussreiches Bild davon, wie sich die Vorverarbeitung auf die Solverauswahl von SATZilla auswirkt.

**1. Die Vorverarbeitung verändert die Vorhersagensverteilung grundlegend**

Die Merkmale von SATZilla sind nicht vorverarbeitungsinvariant. Die von SATZilla berechneten Merkmale – wie beispielsweise das Verhältnis von Variablen zu Klauseln, Grapheigenschaften und Probing-Statistiken – ändern sich wesentlich, wenn eine Formel vereinfacht wird. Dies ist kein Fehler, sondern eine Folge der Tatsache, dass die Vorverarbeitung die Struktur der Formel tatsächlich verändert. Variablen werden eliminiert, Klauseln werden subsumiert, und die allgemeinen Verbindungsmuster des Graphen verschieben sich.

Das heißt aber nicht das die Vorhersagen der vereinfachten Benchmarks dann ünguldig sind, der neue empfohlende Solver kann durchaus als der schnellste sein der dieses (vereinfachte) Problem lösen kann.

**2. Die Vorverarbeitung wirkt sich nicht auf alle Solver gleichermaßen aus**

Die „nostable“-Konfiguration – die die Heuristik der stabilen Phase deaktiviert – wird nach der Vorverarbeitung zum am häufigsten empfohlenen Löser. Ihr Anteil verdoppelt sich fast von 31,9 % auf 50,2 %.

Dies liegt wahrscheinlich daran, dass kissat_nostable sich besonders gut für vereinfachte Formeln eignet. Das Fehlen einer Heuristik für stabile Phasen kann von Vorteil sein, wenn die Formel bereits vereinfacht wurde.

Ein weiter Grund könnte sein da kisat_nostable besser für unsat ist und kissat_stabel2 und kissat_target2 besser für sat, dass dann kissat_stable möglicherweiße ein Mix ist, es könnte auch darauf hinweisen, dass SATZilla sich dann sicherer ist in welche richtung es gehen sollte.

**3. Die meisten Abweichungen treten während der anfänglichen Vereinfachung auf**

Dies deutet auf einen Effekt abnehmender Erträge hin: Die ersten 10.000 Vorverarbeitungsschritte bewirken die dramatischsten Veränderungen im Merkmalsraum. Weitere Vorverarbeitungsschritte (10.000 $\rightarrow$ 100.000) führen zu relativ geringeren zusätzlichen Veränderungen.

**4. Die Vorverarbeitung zeigt die Komplementarität der Solver**

Die Migrationsmuster zeigen, dass verschiedene Solver unterschiedliche "Komfortzonen" im Feature-Raum haben:

- **nostable** gewinnt Instanzen von mehreren anderen Solvern (stable2, default, target2), was darauf hindeutet, dass vorverarbeitete Formeln gemeinsame Eigenschaften aufweisen, die nostable über ein breites Spektrum ursprünglicher Solver-Empfehlungen hinweg zur besten Wahl machen.

- **stable2** verliert Instanzen hauptsächlich an nostable, was darauf schließen lässt, dass die beiden Konfigurationen bei vorverarbeiteten Formeln austauschbar (Substitute) sind oder wieder daran, dass SATZilla sich nun sichere ist das diese Instanz unsat ist.

**5. Es besteht ein eindeutiger Zusammenhang zwischen Dosis und Wirkung**

Eine aggressivere Vorverarbeitung führt zu mehr Änderungen bei den Vorhersagen. Genau das würde ich erwarten, wenn die Merkmale von SATZilla aussagekräftige strukturelle Eigenschaften der Formeln erfassen.

Wären die SATZilla-Features oberflächlich oder vorverarbeitungsinvariant, würde man keinen Anstieg der Änderungsrate bei stärkerer Vorverarbeitung erwarten. Der beobachtete Anstieg (36,8% $\rightarrow$ 41,5%) bestätigt, dass:

- Die Vorverarbeitung die Formelstruktur tatsächlich verändert
- Die SATZilla-Features diese Veränderungen erkennen
- Das Modell auf diese Feature-Änderungen mit aktualisierten Vorhersagen reagiert

Dies ist eine Validierung des SATZilla-Feature-Sets: Die Features sind sensitiv

gegenüber echten strukturellen Veränderungen in der Formel.

### 4.3.1 Fazit

Die Analysen der Verschiebungen in der Vorhersageverteilung, der Änderungsraten über die verschiedenen Vorverarbeitungsstufen hinweg und der Solver-Migrationsmuster ergeben ein einheitliches Bild: Die Vorverarbeitung verändert die Solver-Empfehlungen von SATZilla grundlegend. Bei mehr als einem Drittel der Instanzen (36,8–41,5 %) ändern sich die Vorhersagen, wobei eine aggressivere Vorverarbeitung zu mehr Änderungen führt.

Die Migrationsanalyse zeigt, dass „nostable“ Instanzen von „stable2“, „default“ und „target2“ gewinnt, was darauf hindeutet, dass vorverarbeitete Formeln strukturelle Merkmale aufweisen, die diese Konfiguration begünstigen.

Die Dosis-Wirkungs-Beziehung – mehr Vorverarbeitung führt zu mehr Änderungen – bestätigt, dass die SATZilla-Merkmale empfindlich auf tatsächliche strukturelle Modifikationen in Formeln reagieren, was ihre Nützlichkeit für die Algorithmusauswahl bestätigt.

Zusammenfassend sind die Vorhersagen von SATZilla auf vereinfachte Benchmarks immer noch von großer relevanz, da die veränderten Vorhersagen durch die ebenfalls veränderten Eigenschaften entstanden sind und nicht weil SATZilla wahllos neue Empfehlungen macht.

Trotzdem sollte man in betracht ziehen, dass eine vereinfachung der Benchmarks immer zu verränderten Vorhersagen führen wird und ich hiermit in dieser Arbeit nicht bestätigen werden kann ob es auch dann immer der richtige (schnellste) Solver sein wird.

## 4.4 Vergleich der Featuresbedeutung für Pre10k und Pre100k

Diese Analyse vergleicht die wichtigsten Features, die die Vorhersagen von SATZilla auf leicht vorverarbeiteten (Pre10k) gegenüber stark vorverarbeiteten (Pre100k) Benchmarks bestimmen. Durch das Training separater Random-Forest-Modelle auf jedem Datensatz und die Extraktion der Feature-Wichtigkeiten können wir verstehen:

- Welche Features für die Solver-Auswahl bei vorverarbeiteten Formeln am wichtigsten sind
- Ob sich die Feature-Wichtigkeit mit der Intensität der Vorverarbeitung ändert
- Was dies darüber aussagt, wie die Vorverarbeitung die Formelstruktur beeinflusst

### 4.4.1 Wichtigste Features für jede Vorverarbeitungsstufe

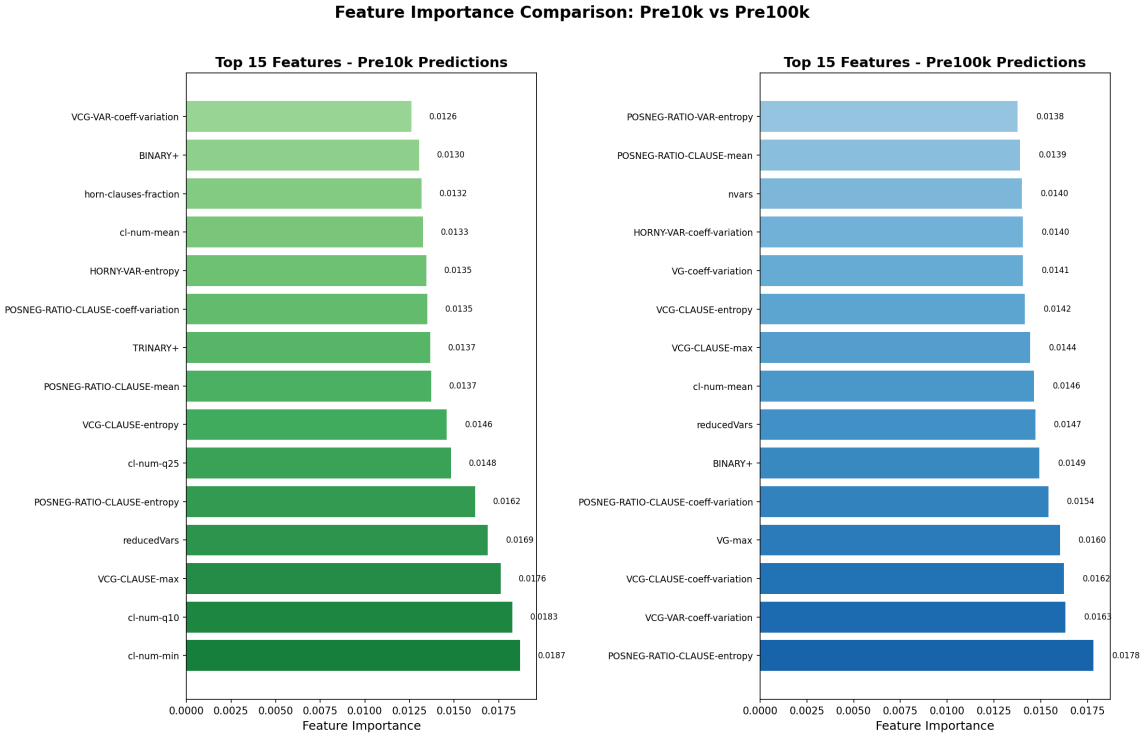


**Figure 13:** Vergleich der Top-15 Features von Pre10k- und Pre100k-Benchmarks

#### Wichtigste Erkenntnise

#### 1. Auf beiden Vorverarbeitungsstufen dominieren dieselben Features

Die Top 10 der Merkmale sind bei Pre10k und Pre100k nahezu identisch, es gibt lediglich geringfügige Verschiebungen in der Rangfolge.

Die grundlegenden Faktoren für die Leistungsfähigkeit eines Solvers sind über alle Vorverarbeitungsstufen hinweg gleich. Selbst nach starker Vereinfachung entscheiden dieselben strukturellen Eigenschaften darüber, welcher Solver am schnellsten ist.

**2. Survey Propagation Features sind am wichtigsten**

SP-unconstraint-q50 (das 50. Perzentil der Wahrscheinlichkeiten für ungebundene Variablen aus der Survey-Propagation) ist das mit Abstand wichtigste Merkmal auf beiden Vorverarbeitungsstufen (Bedeutungswerte 0,0178 und 0,0185).

Die unconstraint Feature spiegelt die „Flexibilität“ der Formel wider. Formeln mit vielen unbeschränkten Variablen können von anderen Lösungsstrategien profitieren als stark eingeschränkte Formeln. Diese Eigenschaft bleibt auch nach der Vorverarbeitung erhalten.

**3. Graph-Based Features sind von großer Bedeutung**

In den Top 10 tauchen mehrere Features mit variable-clause graph (VCG) auf.

Variablen, die in vielen Klauseln vorkommen (hoher Grad), erzeugen Einschränkungen, die sich durch die gesamte Formel auswirken. Die Heuristiken des Solvers für die Variablenauswahl und die Neustartstrategien müssen sich an diese strukturellen Eigenschaften anpassen.

**4. Geringfügige Unterschiede zwischen Pre10k und Pre100k**

| Feature | Pre10k Rang | Pre100k Rang | Änderung |
|---|---|---|---|
| reducedVars | 3 | 2 | Erhöhte Wichtigkeit |
| SP-unconstraint-mean | 12 | 4 | Viel wichtiger |
| SP-unconstraint-q90 | Nicht in Top 15 | 14 | Neu aufgenommen |
| POSNEG-RATIO-VAR-stdev | 9 | 12 | Etwas weniger wichtig |

**Table 18:** Vergleich der Feature-Wichtigkeiten: Pre10k vs Pre100k

Was uns diese Unterschiede sagen:

- „reducedVars“ gewinnt ab Pre100k an Bedeutung. Nach einer intensiven Vorverarbeitung ist die Anzahl der bei der Vereinfachung eliminierten Variablen ein aussagekräftigerer Indikator für die Leistung des Solvers. Das ist einleuchtend: Eine aggressivere Vorverarbeitung eliminiert mehr Variablen und verändert damit grundlegend die Größe und Struktur der Formel.

- Der SP-Mittelwert ohne Einschränkungen springt bei Pre100k von Rang 12 auf Rang 4. Die mittlere Wahrscheinlichkeit ohne Einschränkungen gewinnt nach einer intensiven Vorverarbeitung deutlich an Bedeutung. Dies deutet darauf hin, dass eine intensive Vorverarbeitung zu gleichmäßigeren Verteilungen der Variablen ohne Einschränkungen führt, wodurch der Mittelwert zu einer besseren zusammenfassenden Statistik wird als der Median.

- POSNEG-RATIO-VAR-stdev verliert bei Pre100k an Bedeutung. Die Variabilität der Verhältnisse zwischen positiven und negativen Literalen über die Variablen hinweg verliert nach einer umfassenden Vorverarbeitung an Aussagekraft, möglicherweise weil diese Verhältnisse durch die Vorverarbeitung ausgeglichen werden.

### 4.4.2 Fazit

Die Analyse der Featuressbedeutung zeigt, dass sowohl bei leicht als auch bei stark vorverarbeiteten Benchmarks dieselben strukturellen Eigenschaften die Auswahl des Solvers bestimmen. Merkmale der Survey-Propagation sind durchweg am wichtigsten, gefolgt von Merkmalen des Variablen-Klausel-Graphen und Statistiken zum Klauselernen.

Während die Rangfolge der Merkmale weitgehend stabil bleibt, gewinnen reducedVars und SP-unconstraint-mean bei stärkerer Vorverarbeitung an Bedeutung, was widerspiegelt, wie eine aggressive Vereinfachung Variablen eliminiert und einheitlichere Verteilungen der unbeschränkten Variablen erzeugt.

Diese Ergebnisse bestätigen die Robustheit des Merkmalsatzes von SATZilla über verschiedene Vorverarbeitungsstufen hinweg.

## 4.5 Laufzeitvergleich Pre10k vs. Pre100k

Im Rahmen der Experimente wurde ebenfalls untersucht, wie sich unterschiedliche Grade der Vorverarbeitung (Preprocessing) auf die Gesamtlösungszeit von SAT-Instanzen auswirken. Dabei wurde vollständige die Lösungszeit (Full Runtime) des default Kissats mit der kombinierten Zeit aus Vorverarbeitung (Preprocessing Time) und verbleibender Lösungszeit (Remaining Runtime) verglichen. Die Laufzeiten wurden von dem Tutor Dr. Mathias Fleury brechnet und anschließend zugewiesenen. [1]

**Verglichen wurden drei Szenarien**:

- **Keine Vorverarbeitung**: Vollständige Lösung von Grund auf (Full Runtime)
- **Pre10k**: 10.000 Simplifikationsschritte + verbleibende Lösungszeit
- **Pre100k**: 100.000 Simplifikationsschritte + verbleibende Lösungszeit

**Datenquellen**:[1]

- **Full Runtimes**: kissat-runs-100k-according-to-satzilla.tar.xz (323 Benchmarks)
- **Pre10k-Daten**: sc2024pre10k.zip und kissat-runs-10k-according-to-satzilla.tar.xz (313 gemeinsame Benchmarks)
- **Pre100k-Daten**: sc2024pre100k.zip und kissat-runs-100k-according-to-satzilla.tar.xz (303 gemeinsame Benchmarks)

### 4.5.1 Ergebnisse Pre10k (10.000 Simplifikationsschritte)

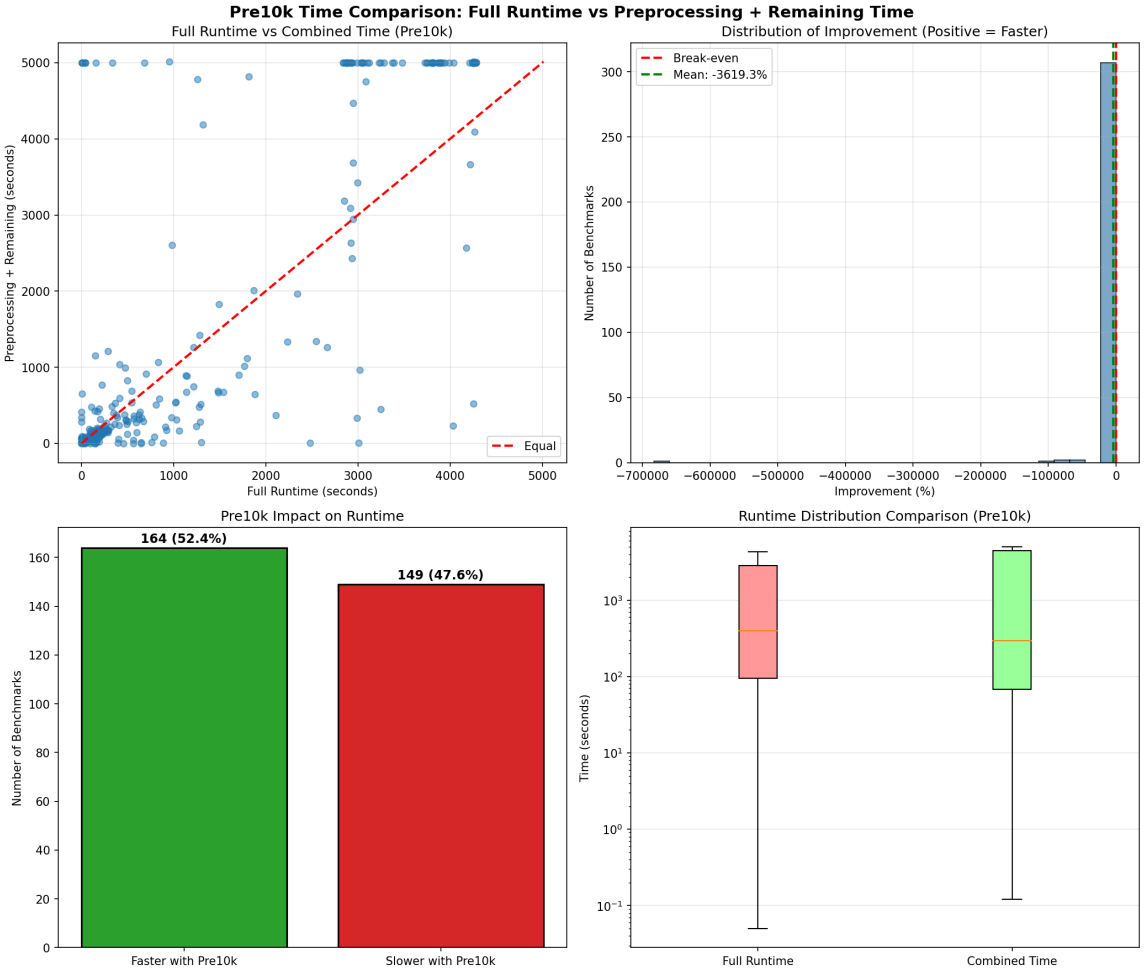


**Figure 14:** Ergebnisse von Pre10k

| Kennzahl | Wert |
|---|---|
| Anzahl Benchmarks | 313 |
| Durchschnittliche Full Runtime | 1241,55 Sekunden (∼20,7 Minuten) |
| Durchschnittliche Preprocessing-Zeit | 1,40 Sekunden |
| Durchschnittliche verbleibende Zeit | 1570,84 Sekunden (∼26,2 Minuten) |
| Durchschnittliche kombinierte Zeit | 1572,24 Sekunden (∼26,2 Minuten) |
| Durchschnittliche Verbesserung | $-330,69$ Sekunden ($-3619,3\%$) |

**Table 19:** Zeitvergleich: Full Runtime vs. Preprocessing + Lösung

Mit der Vereinfachung von Pre10k waren letzendlich 164 Benchmarks (52,4%) schneller zu lösen und 149 (47,6%) waren langsamer.

**Beste Verbesserungen (Beispiele)**:

| Benchmark | Full Runtime | Kombinierte Zeit | Verbesserung |
|---|---|---|---|
| pcmax-scheduling-UNSAT | 566,05s | 0,12s | +100,0% |
| Ptn-7824-b18 | 1303,71s | 12,09s | +99,1% |

**Table 20:** Beispiele für beste Verbesserungen durch Preprocessing

**Schlechteste Verschlechterungen (Beispiele)**:

| Benchmark | Full Runtime | Kombinierte Zeit | Verschlechterung |
|---|---|---|---|
| 1-ZC-512-K-60 | 0,05s | 341,63s | $-683.160\%$ |
| 1-ET-512-K-96 | 5,44s | 5000,23s | $-91.816\%$ |

**Table 21:** Beispiele für schlechteste Verschlechterungen durch Preprocessing

### 4.5.2 Ergebnisse Pre100k (100.000 Simplifikationsschritte)

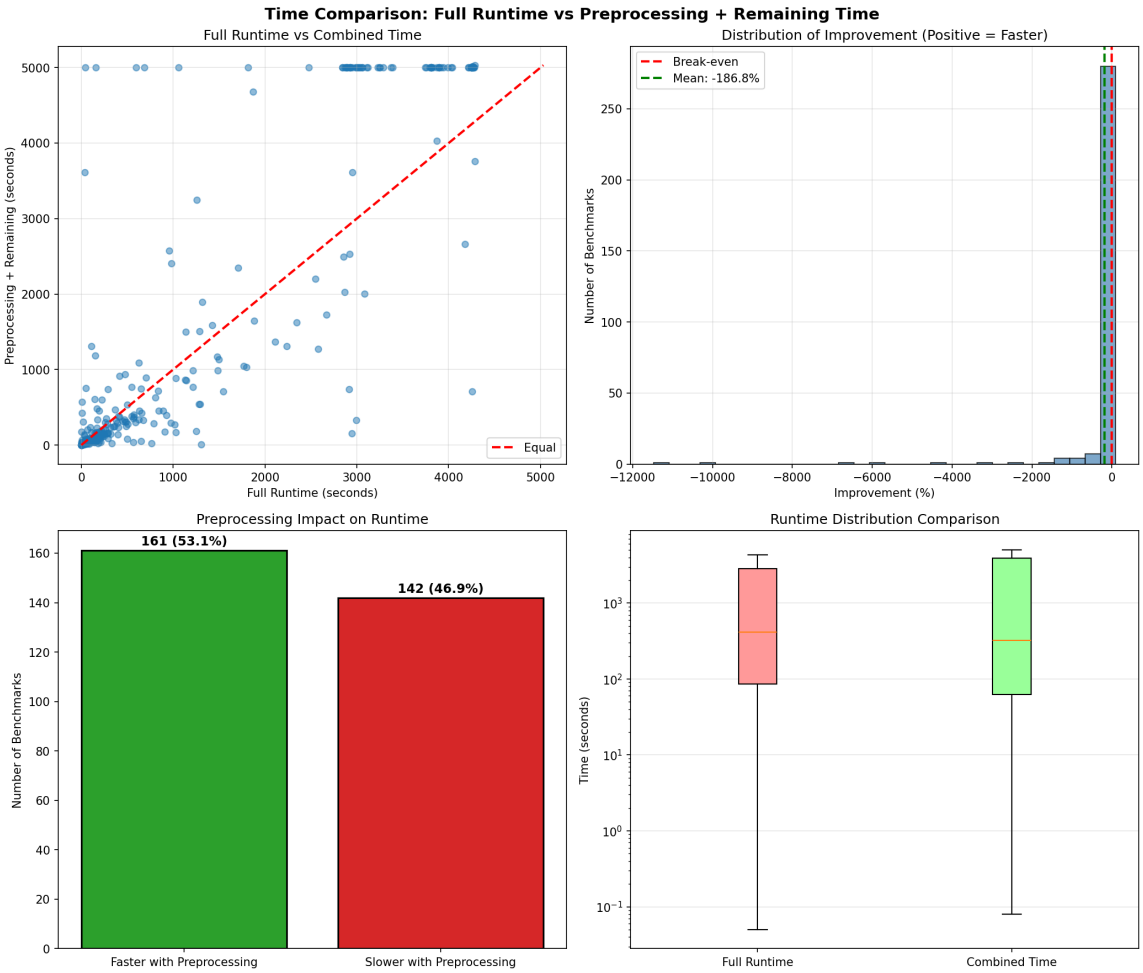


**Figure 15:** Ergebnisse von Pre100k

| Kennzahl | Wert |
|---|---|
| Anzahl Benchmarks | 303 |
| Durchschnittliche Full Runtime | 1252,69 Sekunden (∼20,9 Minuten) |
| Durchschnittliche Preprocessing-Zeit | 2,17 Sekunden |
| Durchschnittliche verbleibende Zeit | 1576,17 Sekunden (∼26,3 Minuten) |
| Durchschnittliche kombinierte Zeit | 1578,34 Sekunden (∼26,3 Minuten) |
| Durchschnittliche Verbesserung | $-325,65$ Sekunden ($-186,8\%$) |

**Table 22:** Zeitvergleich: Full Runtime vs. Preprocessing + Lösung (Pre100k)

Bei der Vereinfachung von pre100k liegt die Verteilung bei 161 Benchamrks die sich verbessert habe (53,1%) wohingegen 142 Benchmarks sich verschlechtert habe (46,9%)

**Beste Verbesserungen (Bispiele)**:

| Benchmark | Full Runtime | Kombinierte Zeit | Verbesserung |
|---|---|---|---|
| Ptn-7824-b18 | 1303,71s | 4,70s | +99,6% |
| battleship-14-26-sat | 2,01s | 0,08s | +96,0% |

**Table 23:** Beispiele für beste Verbesserungen durch Preprocessing (Pre100k)

**Schlechteste Verschlechterungen (Beispiele)**:

| Benchmark | Full Runtime | Kombinierte Zeit | Verschlechterung |
|---|---|---|---|
| EDP3-11000 | 43,22s | 5001,21s | $-11.471\%$ |
| g2-slp-synthesis-aes-top30 | 35,85s | 3610,10s | $-9.970\%$ |

**Table 24:** Beispiele für schlechteste Verschlechterungen durch Preprocessing (Pre100k)

### 4.5.3 Wichtige Erkenntnisse

- **Preprocessing-Zeit**: Pre100k benötigt im Durchschnitt 0,77 Sekunden mehr Vorverarbeitungszeit als Pre10k (2,17s vs. 1,40s). Dies ist erwartungsgemäß, da mehr Simplifikationsschritte durchgeführt werden.

- **Verbleibende Lösungszeit**: Pre100k hat eine minimal höhere verbleibende Lösungszeit (+5,33 Sekunden im Durchschnitt). Dies könnte darauf hindeuten, dass aggressiveres Preprocessing nicht immer zu einer einfacheren Formel führt.

- **Gesamtleistung**: Beide Preprocessing-Stufen schneiden im Durchschnitt schlechter ab als die vollständige Lösung ohne Vorverarbeitung (negative durchschnittliche Verbesserung). Dies ist auf extreme Ausreißer zurückzuführen, bei denen das Preprocessing zu einer massiven Verschlechterung führt.

- **Erfolgsrate**: Pre100k hat eine leicht höhere Erfolgsrate (53,1% schneller vs. 52,4%). Der Unterschied ist jedoch minimal.

- **Extreme Fälle**: Beide Stufen zeigen ähnliche Muster bei extremen Verbesserun-

gen und Verschlechterungen. Besonders auffällig sind Fälle wie `1-ZC-512-K-60`, bei dem Pre10k die Lösungszeit von 0,05 Sekunden auf 341,63 Sekunden verlängert.

### 4.5.4 Interpretation

**Warum ist die durchschnittliche Verbesserung negativ?**

Die negativen Durchschnittswerte (Pre10k: -3619%, Pre100k: -186,8%) sind nicht als wörtliche prozentuale Verbesserungen zu interpretieren. Sie entstehen durch extreme Ausreißer, bei denen sehr kurze Full Runtimes (unter 1 Sekunde) durch Preprocessing auf Zeiten um 5000 Sekunden ansteigen. Diese Ausreißer verzerren den Durchschnitt stark.

**Beispiel**: 1-ZC-512-K-60 (Full Runtime: 0,05s $\rightarrow$ Pre10k: 341,63s) allein verursacht eine scheinbare Verschlechterung von über 600.000%.

Somit soll man Preprocessing nicht als Allheilmittel betrachten, da es in etwas der Hälfte der Fälle die bearbeitungszeit verschlechtert. Des weiteren sieht man das es keinen großen Unterschied macht wie stark man die Benchamrks vereinfacht. Preprocessing sollte man meiner Meinung dann nur anwenden auf Benchmarks für die es tatsächlich auch wirkt.

### 4.5.5 Fazit

Die Untersuchung zeigt, dass sowohl Pre10k (10.000 Simplifikationsschritte) als auch Pre100k (100.000 Simplifikationsschritte) in etwa der Hälfte der Fälle (52-53%) zu einer Beschleunigung der Lösungszeit führen. Die durchschnittliche Preprocessing-Zeit ist mit 1,4 bis 2,2 Sekunden vernachlässigbar gering. Allerdings kann Preprocessing in einigen Fällen zu extremen Verlangsamungen führen (bis zu Faktor 10.000), was die durchschnittliche Verbesserung verzerrt. Ein signifikanter Vorteil von Pre100k gegenüber Pre10k konnte ich daher nicht festgestellen. Für die praktische Anwendung wird daher eine selektive, instanzabhängige Aktivierung des Preprocessings empfohlen.

# 5 Conclusion

In dieser Arbeit wurde untersucht, ob und wie gut SATZilla – ein auf maschinellem Lernen basierendes Algorithmus-Portfolio – für die Auswahl zwischen verschiedenen Konfigurationen des modernen CDCL-SAT-Solvers Kissat eingesetzt werden kann. Die Experimente umfassten drei Hauptphasen: (1) Validierung der Pipeline mit künstlichen ("Fake")-Solvern, (2) Training und Evaluation auf sechs realen Kissat-Varianten mit den ursprünglichen Benchmarks sowie (3) Analyse der Auswirkungen von Vorverarbeitung auf die Vorhersagen und Laufzeiten.

Erstens bestätigt die erfolgreiche Validierung mit Fake-Solvern, dass die SATZilla-Pipeline – von der Feature-Extraktion über das Training bis zur Vorhersage – korrekt implementiert ist. Die hohe Genauigkeit und die plausible Features beweisen, dass das Verfahren lernen kann.

Zweitens zeigt die Anwendung auf sechs echte Kissat-Varianten, dass man SATZilla darauf trainieren kann und nutzbare Vorhersagen liefert. Mit einer Top-3-Genauigkeit von 85 % und einem durchschnittlichen Speedup von 1,47 gegenüber dem Standard-Solver ist SATZilla nicht nur besser als ein Zufallsverfahren, sondern auch praktisch nützlich für die portfoliogestützte SAT-Lösung. Die Analyse der Features offenbart zudem, welche strukturellen Eigenschaften einer Instanz für die Leistungsunterschiede der Kissat-Varianten verantwortlich sind – ein Erkenntnisgewinn, der über die reine Solver-Auswahl hinausgeht.

Drittens belegt die Untersuchung der Vorverarbeitung, dass SATZillas Vorhersagen nicht vorverarbeitungsinvariant sind. Die Änderungen der Solver-Empfehlungen sind eine direkte Folge der tatsächlichen strukturellen Veränderungen der Formeln, nicht willkürlich. Die Dosis-Wirkungs-Beziehung (mehr Vorverarbeitung $\rightarrow$ mehr Änderungen) validiert die Sensitivität des Feature-Sets. Für die praktische Anwendung bedeutet dies, dass SATZilla in diesem Fall Vorhersagen macht die Zutreffender sein könnten.

Viertens zeigt der Laufzeitvergleich, dass Vorverarbeitung kein Allheilmittel ist: Sie beschleunigt zwar etwa die Hälfte der Instanzen, kann in Einzelfällen aber zu extremen Verlangsamungen führen. Ein signifikanter Vorteil von 100.000 gegenüber 10.000 Vereinfachungsschritten konnte nicht festgestellt werden.

## 5.1 Technische Daten

Die Erstellung der Arbeit erfolgte auf einem lokalen Windows-11-Rechner mittels WSL. Für rechenintensive Berechnungen wurde eine SSH-Verbindung zu einem Rechner der Technischen Fakultät genutzt, was insbesondere aufgrund des erhöhten Arbeitsspeicherbedarfs im vorausgegangenen Bachelorprojekt von Vorteil war. Die Nutzung von Tmux erwies sich als vorteilhaft für die Ausführung längerer Rechenprozesse.

Die Implementierung der Skripte erfolgte in Python 3.9 unter Verwendung folgender Bibliotheken: NumPy, Pandas, scikit-learn (insbesondere Random Forest), Matplotlib (für Diagramme und Visualisierungen), Seaborn, Joblib, Plotly, TQDM sowie Requests. Die Ausführung der Skripte wurde mittels Conda verwaltet.

# List of Figures


1 Kissat SAT Solver [8] . . . . . 6
2 Testgenauigkeit der verschiedenen Strategien . . . . . 17
3 Vergleich mit Random Selection . . . . . 17
4 Zusammenfassung der Besten Solver . . . . . 18
5 Vergleich der drei besten Solver mit Zufallsprinzip . . . . . 18
6 Für jeden solver Top 3 Vorhersagen . . . . . 19
7 Wichtigste Features für die Vorhersagen . . . . . 21
8 Vorhersagen Genauigkeit nach Solver . . . . . 27
9 Vorhersagen Korrektheit nach Solver . . . . . 27
10 Solver-Verteilung für Original-, Pre10k- und Pre100k-Benchmarks . . . 37
11 Anzahl der Solver Änderungen für Original-, Pre10k- und Pre100k-Benchmarks . . . . . 38
12 Änderung der jeweiligen Solver für Original-, Pre10k- und Pre100k-Benchmarks . . . . . 41
13 Vergleich der Top-15 Features von Pre10k- und Pre100k-Benchmarks . 45
14 Ergebnisse von Pre10k . . . . . 49
15 Ergebnisse von Pre100k . . . . . 51

# List of Tables


1 Kissat-Konfigurationsvarianten für diese Arbeit . . . . . 9
2 SAT Instance Features Categories . . . . . 11
3 Testergebnisse für verschiedene Auswahlstrategien . . . . . 14
4 Testergebnisse der wichtigsten Features . . . . . 14
5 Speedup-Kennzahlen von Satzilla gegenüber kissat_default . . . . . 20
6 VCG Klausen Features and ihre wichtigkeit . . . . . 22
7 Preprocessing Features and ihre wichtigkeit . . . . . 23
8 Preprocessing Features and ihre wichtigkeit . . . . . 24
9 Klausel länge Features and ihre wichtigkeit . . . . . 24
10 Basic size Features and ihre wichtigkeit . . . . . 25
11 Feature Kategorien und ihre wichtigkeit . . . . . 26
12 Unterschied der Vorhersage mit LP-Features . . . . . 29
13 Feature Extraction Statistics . . . . . 35
14 Random Forest Konfigurationsparameter . . . . . 35
15 Solver Selection Distribution (%) . . . . . 38
16 Vorhersageänderungen zwischen verschiedenen Vorverarbeitungsstufen 39
17 Häufigste Änderungen (Original → Pre10k) . . . . . 41
18 Vergleich der Feature-Wichtigkeiten: Pre10k vs Pre100k . . . . . 46
19 Zeitvergleich: Full Runtime vs. Preprocessing + Lösung . . . . . 49
20 Beispiele für beste Verbesserungen durch Preprocessing . . . . . 50
21 Beispiele für schlechteste Verschlechterungen durch Preprocessing . . 50
22 Zeitvergleich: Full Runtime vs. Preprocessing + Lösung (Pre100k) . . . 51
23 Beispiele für beste Verbesserungen durch Preprocessing (Pre100k) . . 52
24 Beispiele für schlechteste Verschlechterungen durch Preprocessing (Pre100k) . . . . . 52

# References


[1] Betreuer der Arbeit. Kissat strategy runs and preprocessed benchmarks for satzilla experiments. Nextcloud der Universität Freiburg, 2025. Zugang über Studienaccount.

[2] Armin Biere. Kissat sat solver. GitHub / fmv.jku.at, 2020. Offizielle Beschreibung: "keep it simple and clean bare metal SAT solver".

[3] Armin Biere, Katalin Fazekas, Mathias Fleury, and Maximilian Heisinger. Cadical, kissat, paracooba, plingeling and treengeling entering the sat competition 2020. In *Proc. of SAT Competition 2020 - Solver and Benchmark Descriptions*, volume B-2020-1 of *Department of Computer Science Report Series B*, pages 50–53, Helsinki, 2020. University of Helsinki.

[4] Armin Biere, Marijn Heule, Hans van Maaren, and Toby Walsh. Conflict-driven clause learning. In *Handbook of Satisfiability*, pages 133–182. IOS Press, 2 edition, 2021. Kapitel 4: Enthält Grundlagen zu Verzweigungsheuristiken und Phase Saving.

[5] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

[6] Stephen A. Cook. The complexity of theorem-proving procedures. In *Proceedings of the 3rd Annual ACM Symposium on Theory of Computing (STOC '71)*, pages 151–158, New York, NY, USA, 1971. ACM.

[7] Jan Elffers, Jan Johannsen, Massimo Lauria, and Jakob Nordström. Towards a complexity-theoretic understanding of restarts in SAT solvers. In *Theory and Applications of Satisfiability Testing – SAT 2020*, volume 12178 of *Lecture Notes in Computer Science*, pages 239–255. Springer, 2020.

[8] Institute for Formal Models and Verification. Kissat sat solver. `https://fmv.jku.at/kissat/`, 2020. Abgerufen am 01.05.2026.

[9] Eugene Nudelman, Alex Devkar, Yoav Shoham, Kevin Leyton-Brown, and Holger H. Hoos. Satzilla : An algorithm portfolio for sat. In *Proceedings of the 19th National Conference on Artificial Intelligence (AAAI-04)*. AAAI Press, 2004.

[10] Dhiraj K. Pradhan and Ian G. Harris. Boolean satisfiability and EDA applications. In *Practical Design Verification*, pages 174–196. Cambridge University Press, 2012. Kapitel 8.

[11] Dhiraj K. Pradhan and Ian G. Harris. Boolean satisfiability and EDA applications. In *Practical Design Verification*, pages 174–196. Cambridge University Press, 2012. Kapitel 8 (insb. Abschnitt ‚Introduction').

[12] SAT Competition Organizers. Sat competition 2024. Webseite, 2024. Benchmarks für SAT-Solver.

[13] SAT Competition Organizers, editor. *Proceedings of the SAT Competition 2025*, 2025. Verfügbar unter: https://satcompetition.github.io/2025/.

[14] Hadar Shavit and Holger H. Hoos. Revisiting SATZilla features in 2024. In *Proceedings of the 27th International Conference on Theory and Applications of Satisfiability Testing (SAT 2024)*, volume 305 of *Leibniz International Proceedings in Informatics (LIPIcs)*, pages 27:1–27:27, 2024.

[15] Hadar Shavit and Holger H. Hoos. Satzilla sat feature extraction tool. GitHub, 2024. Version v0.0.1.

[16] Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. Satzilla: Portfolio-based algorithm selection for sat. *Journal of Artificial Intelligence Research (JAIR)*, 32:565–606, 2008.

[17] Lin Xu, Frank Hutter, Holger H. Hoos, and Kevin Leyton-Brown. Evaluating component solver contributions to portfolio-based algorithm selectors. In *Proceedings of the 15th International Conference on Theory and Applications of Satisfiability Testing (SAT)*, pages 228–241, 2012. Zitat zu ‚solvers contributing most to SATzilla were often not the overall best'.